

D-MeZO-N: Децентрализованный федеративный MeZO с Nesterov-стабилизацией

Максим Сухацкий — МГТУ им. Н.Э. Баумана (Калужский филиал) — loxtrepoi@gmail.com — github.com/Siesher/dmezo

Весна 2026

Аннотация

Мы представляем **D-MeZO-N** — Decentralized Federated MeZO, децентрализованный федеративный MeZO с **Nesterov-стабилизацией** — peer-to-peer федеративный zeroth-order оптимизатор для дообучения больших языковых моделей с формальным анализом momentum stability под bounded variance. Опираясь на MeZO (Malladi et al., NeurIPS 2023, memory-efficient zeroth-order), мы заменяем одномашинную постановку на n клиентов, связанных дважды-стохастической mixing-матрицей W (Koloskova et al. 2020), где каждый клиент **независимо** сэмплирует своё направление z_i и передаёт соседям только один скаляр (проекцию ρ_i) + один seed за раунд — что устраняет гигабайтные обмены градиентами FedAvg и при этом обеспечивает $1/n$ variance reduction по обеим компонентам шума (data + direction). Для стабилизации heavy-ball момента под высокой дисперсией ZO-оценок мы вводим **adaptive ρ -clipping** (running 95-percentile $\times 1.3$) совместно с **drift-reset** (зануление velocity при детекции uptick eval-loss) и линейным β -decay $0.9 \rightarrow 0$ — рецепт D-MeZO-N v2 (combo). На **Qwen3.5-4B-Base / MathLogicQA / 3 paired seeds** **D-MeZO-N v2** достигает **final loss 1.2926 ± 0.010 vs vanilla MeZO 1.3681 ± 0.018 ($\Delta = -5.5\%$, 3/3 same direction, paired $t = 5.3$, $p < 0.05$)** — первое paper-scale multi-seed validated empirical улучшение D-MeZO над vanilla MeZO. Точность по итогу демонстрирует положительную, но статистически незначимую тенденцию (+2.3pp в среднем; по seed-ам: $\{-1, +8, 0\}$ pp; paired $t \approx 0.8$, $p \approx 0.5$; eval-пул 100 примеров, $SE \approx 4.9pp$) — приводим для прозрачности, не заявляем как улучшение. Компоненты по отдельности либо falsified (v1 fixed clip $C=50$ — 3/3 worse, +7.0% loss; drift-reset alone — 3/3 worse), либо seed-specific по accuracy (B1 adaptive_clip alone). Combo достигает **наименьшего std loss среди вариантов, улучшающих vanilla** (0.010 vs adaptive_clip alone 0.021; сам vanilla 0.018) — дополнительная метрика устойчивости. (Drift-only имеет ещё меньший std loss 0.0035, но это отражает то, что он равномерно «застрял» на худшем loss (+6.4%), а не стабильность хорошего решения.) Эмпирику дополняют четыре формальные теоремы сходимости — **Теорема 1** (выпуклый + момент, ρ -clipping, decentralized), **Теорема 2** (невыпуклый PL без момента, federated $1/n$ speedup), **Теорема 3** (PL + heavy-ball + β -decay + ρ -clip; Lyapunov $V_t = (L - L^*) + (\eta/2)\|v\|^2$; насколько нам известно, первая гарантия устойчивости ZO heavy-ball в PL-режиме) и **Теорема 4** (DP-расширение T3 с dual-use ρ -clip как L2-sensitivity, per-round ($\varepsilon = 10$, $\delta = 10^{-3}$)-DP с $\sim 6\%$ utility cost). **Theorem 3 rate matches plain SGD под PL — асимптотическое ускорение не заявляется** (согласуется с Bottou-Curtis-Nocedal 2018 T5.1); transient acceleration наблюдается эмпирически и остаётся open problem. Весь код, конфиги, MLflow run ID и 128 unit-тестов публичны.

1. Введение

Memory-efficient zeroth-order оптимизация (MeZO) для больших языковых моделей была введена Malladi et al. (2023) как неожиданный результат: дообучение LLM с миллиардами параметров можно делать только через forward-passes, со стоимостью памяти как при инференсе. Ключевой приём — замена backpropagation двухточечной оценкой градиента по случайному направлению, восстанавливаемому из seed-а — сжимает состояние оптимизатора с $O(d)$ (моменты Adam) до $O(1)$ (один скаляр). Для федеративного обучения это преобразующе: вместо передачи плотных градиентов (или их сжатых аппроксимаций) клиенты MeZO обмениваются только парами (s, ρ) .

Однако существующая литература по федеративному MeZO (FedKSeed, Ferret, FedZeN) ограничена (а) единой full-attention архитектурой (семейство OPT, LLaMA), и (б) центрально-агрегированной топологией FedAvg (McMahan et al. 2017). Перенос результатов distributed SPSSA (современным воплощением которого является MeZO) — consensus-based вариантов, accelerated schemes, расширений с моментом Нестерова — в область дообучения LLM оставался открытым вопросом.

В этой статье мы закрываем пробел восемью контрибуциями (C1–C8):

- **C1** — Первое федеративное применение MeZO на гибридной linear-attention LLM (Qwen3.5-4B-Base, layer_types = [linear, linear, linear, full] $\times 8$ в text decoder, плюс замороженный 24-слойный ViT).
- **C2** — D-MeZO устойчив к экстремальной неоднородности распределения: партиционная «стоимость» $\text{Dirichlet}(\alpha=0.5) \leq 13\%$ относительно IID (по 2 seed-ам Day 5 grid).
- **C3** — Разница между топологиями $\leq 8\%$ при $n = 4$ клиентах; контр-интуитивно, ring(4) сравним или лучше complete(4) на ZO-режиме на обоих распределениях.
- **C4** — **D-MeZO-N v2 = combo (adaptive p-clip B1 + drift-reset B5)** на paper-scale (Qwen3.5-4B-Base / MathLogicQA / 3 seeds paired): final loss 1.2926 ± 0.010 vs vanilla 1.3681 ± 0.018 ($\Delta = -5.5\%$, 3/3 same direction, paired $t = 5.3$, $p < 0.05$). Combo достигает **наименьшего std loss среди вариантов, улучшающих vanilla** (0.010 vs adaptive_clip alone 0.021; сам vanilla 0.018) — дополнительная метрика устойчивости. (Drift-only имеет ещё меньший std loss 0.0035, но он равномерно «застрял» на худшем loss (+6.4%) — это не стабильность хорошего решения.) Это первое paper-scale multi-seed validated empirical улучшение D-MeZO-N над vanilla MeZO. Для прозрачности: точность 0.400 vs 0.377 (+2.3pp в среднем; per-seed $\{-1, +8, 0\}$ pp; paired $t \approx 0.8$, $p \approx 0.5$) — статистически незначима (eval-пул 100 примеров, $SE \approx 4.9\text{pp}$) и не заявляется как самостоятельное улучшение.
- **C5** — Independent z_i per client (а не shared z как у FedKSeed) обеспечивают $1/n$ variance reduction по обоим источникам шума: data sampling и direction sampling. Передаётся (s_i, ρ_i) — 16 байт/раунд/сосед при update_share consensus; vanilla weight_avg — $O(d)$ для full parameter exchange.
- **C6** — Theorem 3: closed-form Lyapunov-сходимость для PL + heavy-ball + ρ -clip + β -decay с rate $(1 - 3\eta\mu/2)$ и neighbourhood $2G^2/(3\mu)$, где $G^2 \leq C^2 r(H)\ell$. Теорема 3 устанавливает устойчивость zeroth-order оптимизации с heavy-ball моментом при адаптивном клиппинге и β -decay в PL-режиме — насколько нам известно, первая такая гарантия в ZO-LLM постановке. Скорость сжатия $(1 - 3\eta\mu/2)$ не превосходит скорость plain SGD под PL $(1 - 2\eta\mu)$ (Karimi et al. 2016), что согласуется с Bottou–Curtis–Nocedal 2018 (Thm 5.1): heavy-ball не даёт асимптотического ускорения при стохастических градиентах. Наш вклад — момент можно сделать безопасным (без расхождения) в высокодисперсном ZO-режиме, а не быстрее. Transient empirical speedup на Day 8 R1b (R100→R300, 3 $\times$) остаётся open problem.
- **C7** — Theorem 4: DP-расширение T3 через **dual-use ρ -clip** — тот же C , что используется для momentum stability, **одновременно служит L2-sensitivity** для Gaussian механизма Дворка-Рота. Per-round ($\epsilon = 10$, $\delta = 10^{-3}$)-DP с ~6% utility cost на Qwen3.5-0.8B / MathLogicQA. T-round composition признаётся explicit limitation; subsampling amplification (Abadi 2016) — future work.
- **C8** — Honest negatives multi-seed validated: D-MeZO-N v1 (fixed $C = 50$) — 3/3 worse (+7.0% loss); B5 drift-reset alone — 3/3 worse (+6.4% loss); look-ahead Nesterov diverges R20 (7 $\times$ faster than heavy-ball); K=3 multi-direction equal-compute loses; $\epsilon(t)$ warmup schedules robustly lose const 10^{-3} across 16+ cells. Эти falsifications — clean evidence о scope применимости method.

Предсказания Теорем 1–4 (линейная PL-сходимость, blow-up без clip, late drift при const- β , monotonic descent при β -decay, $1/n$ stochastic floor, consensus-штраф $\rho_W^2/(1 - \rho_W)^2$, ZO bias $O(\epsilon^2)$, DP-noise scales с d а не $r(H)$) эмпирически подтверждены — directional match.

2. Связанные работы

SPSA — foundational ancestor. Simultaneous Perturbation Stochastic Approximation (Spall 1992, IEEE TAC 37:332) — двухточечный zeroth-order оптимизатор, лежащий в основе всей последующей ZO-литературы. Original SPSA использует Bernoulli ± 1 perturbation Δ и обновление $\theta \leftarrow \theta - \eta \cdot ((L(\theta + \varepsilon\Delta) - L(\theta - \varepsilon\Delta))/(2\varepsilon)) \cdot \Delta^{-1}$. Convergence rate $O(1/\sqrt{T})$ (Sadegh-Spall 1998); 2-SPSA с Hessian estimation — Spall 2000; adaptive gain schedule $\eta_t = a/(t + A)^\alpha$ ($\alpha \approx 0.602$) — Spall 1997. SPSA не предназначен для масштабов LLM из-за explicit storage возмущения Δ ($O(d)$ память) — этот gap закрывает MeZO.

MeZO — SPSA для LLM. Malladi et al. (2023, NeurIPS) ввели MeZO как SPSA с двумя ключевыми innovations: (i) **Gaussian** $z \sim \mathcal{N}(0, I)$ вместо Bernoulli (даёт $r(H)$ -trick, ниже), (ii) **in-place seed-reconstructed** z — direction z регенерируется детерминированно из seed-a, не материализуется как тензор $\rightarrow$ память остаётся inference-level. Они показали дообучение OPT-{1.3B, 13B, 30B, 66B} на SuperGLUE с памятью, сравнимой с инференсом. Теорема 3.1 доказывает variance bound через эффективный ранг гессиана $r(H) := \text{tr}(H)/\|H\|_{op}$ вместо полной размерности d — это и обеспечивает применимость на LLM-масштабе ($r(H) \ll d$ для overparametrized трансформеров).

ℓ_2 -smoothing анализ (русская школа). Параллельно с SPSA развивалась традиция Gaussian/uniform smoothing для convex ZO (Nesterov, Spokoiny 2017, FOCM). Gasnikov et al. (2023, “Randomized gradient-free methods in convex optimization”, *Encyclopedia of Optimization*, arXiv:2211.13566) систематизировали этот фреймворк: two-point estimator $\nabla f_\gamma(x, e) = d \cdot \frac{f(x+\gamma e) - f(x-\gamma e)}{2\gamma} \cdot e$ для $e \sim \text{Unif}(S_2^d)$, bias bound $f(x) \leq f_\gamma(x) \leq f(x) + \gamma M_2$ и variance bound $\mathbb{E}\|\nabla f_\gamma\|^2 \leq \sqrt{2} \min(q, \ln d) d^{2/q} M_2^2$. Эти оценки — формальный фундамент наших convergence proofs T1-T4. Survey покрывает convex/strongly convex случаи с accelerated rates; PL + heavy-ball режим (на котором стоит D-MeZO-N) survey не охватывает — это наш delta.

D-MeZO-N — SPSA + MeZO + 4 новых элемента. Наш метод строится на SPSA-родословной (34 года теории stochastic approximation) и добавляет: (1) federated wrapper с independent per-client z_i + gossip mixing matrix W (vs FedKSeed-style shared seed pool), (2) heavy-ball scalar momentum с adaptive ρ -clip + drift-reset (vs SPSA’s adaptive gain без momentum), (3) closed-form Lyapunov convergence proof под PL — первая гарантия устойчивости ZO heavy-ball в PL-режиме (Theorem 3; скорость сжатия совпадает с plain SGD под PL, асимптотическое ускорение не заявляется), (4) dual-use ρ -clip как L2-sensitivity для Gaussian-mechanism DP (targeted search для “DP-SPSA” вернул empty — open niche).

Децентрализованный SGD. Koloskova et al. (2020, «A Unified Theory of Decentralized SGD») дают унифицированный анализ D-SGD с произвольной mixing-матрицей W . Их Теорема 2 (выпуклый случай) и Теорема 8 (PL) ограничивают rate сходимости в зависимости от спектральной щели $\rho(W)$ и неоднородности градиентов ζ^2 ; фреймворк включает методы с локальными обновлениями (Stich 2019). Эти оценки — наша отправная точка для комбинирования ZO-дисперсии MeZO с штрафом за федеративную топологию. Параллельно, Beznosikov, Richtárik et al. (NeurIPS 2022, arXiv:2207.10792) развивают decentralized SGD с communication compression для вариационных неравенств — VI-аналог нашей «16 байт/раунд» экономии; Sadiev et al. (2022, *EURO J Comp Opt*) дают lower bounds для decentralized personalized FL, ограничивающие optimality нашего T1 снизу.

Федеративный zeroth-order. FedKSeed (Qin et al., ICML 2024) и Ferret (Shu et al., 2024) — оба строятся на MeZO для FL, используя общие словари seed-ов для дальнейшего сжатия коммуникации. FedZeN (Maritan et al. 2024) исследует Newton-стиль zeroth-order в FL. Все три работы ограничены (i) full-attention архитектурами и (ii) центрально-агрегированной FedAvg топологией; ни одна из них не рассматривает peer-to-peer децентрализованный случай с heavy-ball Nesterov-стабилизацией. DeComFL (Li et al. 2024, ICLR 2025) аналогично сжимает FL-коммуникацию до

$O(1)$ скаляров за раунд через shared-seed zeroth-order и доказывает dimension-free rate при low-effective-rank, но остаётся server-orchestrated с одним общим seed на раунд. D-MeZO-N отличается по всем трём осям: peer-to-peer gossip по любой дважды-стохастической W , **независимые** z_i у каждого клиента (источник $1/n$ редукции по обоим компонентам шума, §4.4) и анализ устойчивости момента (Теорема 3).

Heavy-ball под PL. Yang, Lin, Li (2016) дают унифицированный анализ Ляпунова для heavy-ball SGD в выпуклом и невыпуклом PL режимах; Aybat et al. (2019) дают универсально оптимальный многоэтапный ускоренный метод. Karimi, Nutini, Schmidt (2016) устанавливают канонический фреймворк линейной сходимости к шумовому floor для стохастических градиентных методов под PL.

Гибридные linear-attention LLM. Qwen3.5-4B-Base (выпуск 2026) — V-L модель, где text decoder сочетает 24 linear-attention слоя (вариант gated DeltaNet) с 8 full-attention слоями в периодической схеме «8-блок». Насколько нам известно, ни одна zeroth-order федеративная статья пока не оценивала этот класс архитектур.

3. Метод: D-MeZO-N

3.1 Постановка

Пусть n клиентов хранят локальные шарды данных D_i и локальные копии параметров модели $\theta_i \in \mathbb{R}^d$. Связность задаётся дважды-стохастической mixing-матрицей $W \in \mathbb{R}^{n \times n}$ со спектральной щелью

$$\rho(W) := \|W - \frac{1}{n} \mathbf{1}\mathbf{1}^\top\|_{op} \in [0, 1).$$

$\rho(W) = 0$ соответствует полносвязной топологии — точное среднее за один раунд; $\rho(W) \rightarrow 1$ соответствует разрыву графа. Для топологии «кольцо» $n = 4$ (используемой в наших экспериментах) $\rho(W) \approx 0.333$.

3.2 Алгоритм

На раунде t каждый клиент i выполняет MeZO-шаг с новым seed-ом s_i^t (из per-client counter-PRNG), производя проекцию градиента

$$\hat{g}_i^t = \frac{L(\theta_i^t + \epsilon z) - L(\theta_i^t - \epsilon z)}{2\epsilon},$$

где $z \sim \mathcal{N}(0, I)$ восстанавливается из seed-а s . Полный раунд D-MeZO-N комбинирует ρ -clip шаг, heavy-ball (Polyak 1964) обновление скорости v (возможно расписанным) коэффициентом момента β_t , шаг по параметрам и consensus mixing:

$$\begin{aligned} v_i^{t+1} &= \beta_t v_i^t + \text{clip}(\hat{\rho}_i^t, \pm C) z_{s_i^t}, \\ \theta_i^{t+1/2} &= \theta_i^t - \eta v_i^{t+1}, \\ \theta_i^{t+1} &= \sum_j W_{ij} \theta_j^{t+1/2}. \end{aligned}$$

При $\beta_t = 0$ алгоритм сводится к vanilla D-MeZO (наш baseline). При $\beta_t > 0$ и включённом ρ -clipping это D-MeZO-N. Мы предлагаем два режима расписания: постоянный $\beta_t = 0.9$ (R1b в §5) и линейный спад $\beta_t = \beta_0 \cdot (1 - t/T)$ с $\beta_0 = 0.9, \beta_{\text{end}} = 0$ (R1d, наш рекомендованный рецепт).




Рисунок 1. Алгоритм D-MeZO-N для $n = 4$ клиентов на кольцевой топологии. Каждый клиент независимо выполняет локальный MeZO-замер (seed s_i , скаляр ρ_i), клипает ρ_i , обновляет локальный буфер скорости с расписанным β_t , и затем участвует в дважды-стохастическом consensus-усреднении с соседями. Коммуникация — $O(1)$ скаляров + 1 seed на соседа за раунд.

3.3 ρ -clipping (мотивация Леммы 2)

Проекция градиента MeZO $\hat{\rho}$ имеет дисперсию, ограниченную Леммой 1 ниже, но на практике отдельные значения $\hat{\rho}$ могут «всплескаться» на 2–3 порядка из-за тяжёлых хвостов оценки $(L(\theta + \epsilon z) - L(\theta - \epsilon z))/2\epsilon$ вблизи негладких точек loss-ландшафта LLM (мы наблюдали отдельные пики $|\hat{\rho}| \approx 900$ в первых раундах при типичной величине $|\hat{\rho}| \approx 100$). Без ограничения таких пиков буфер скорости Нестерова $v_i = \beta v_i + \hat{\rho} z$ аккумулирует их с steady-state амплифайером $1/(1 - \beta^2) \approx 5.3$ при $\beta = 0.9$, что приводит к катастрофической расходимости на раунде $R \approx 140$ (см. §5.4). Мы ограничиваем вклад в v_i на каждом шаге симметричным клипом:

$$\text{clip}(x, \pm C) := \max(-C, \min(C, x)).$$

Порог $C = 50$ выбран эмпирически (ловит все наблюдаемые пики, сохраняя ~95% сигнала в нормальном диапазоне). Лемма 2 в §4 количественно описывает возникающий bias-variance trade-off.

3.4 Стоимость коммуникации

За раунд каждому соседу клиент передаёт текущее $\hat{\rho}_i$ (один float) и seed s_i (одно целое число) — 16 байт. Для модели на 4 миллиарда параметров в bf16 (8 ГБ плотного градиента) это $8 \text{ ГБ}/16 \text{ байт} = 5 \cdot 10^8$ -кратное сжатие (почти девять порядков) по сравнению с обменом плотными градиентами в FedAvg:

$$\text{Comm} = O(1) \text{ скаляр} + 1 \text{ целое seed на соседа за раунд.}$$

3.5 Инженерные контрибуции

Помимо метода D-MeZO-N, репозиторий содержит инженерные артефакты, делающие peer-to-peer ZO-федерализацию на современных open-weight LLM **воспроизводимой**:

- **In-process федеративный симулятор** (src/dmezo/federated/): generic over n клиентов и любую дважды-стохастическую mixing-матрицу. Поддерживает два consensus-режима: `weight_avg` (полный обмен

параметрами) и `update_share` (peer-to-peer обмен только $(\hat{\rho}_i, s_i)$ парами). Reconciliation между режимами bit-exact для plain MeZO (vanilla), отделена для Nesterov-варианта (audit-harden D1: Nesterov + `update_share` not yet integrated; используется `weight_avg`).

- **Hybrid linear-attention loader** (`src/dmezo/models/loader.py`): автоматически распознаёт Qwen3.5-family как `AutoModelForImageTextToText`, замораживает 24-слойный ViT и преобразует loader так, чтобы MeZO возмущала только text decoder (426 trainable parameter groups). Это первая известная имплементация zeroth-order fine-tuning на hybrid linear/full-attention architecture.
- **Seed-based perturbation без материализации z** (`src/dmezo/mezo/perturbation.py`): возмущение применяется in-place через `param.data += eps * z(s)` где $z(s)$ генерируется детерминированно из `torch.manual_seed(s)`. Памяти на z не выделяется — критический инвариант для memory-efficiency MeZO на LLM-масштабе.
- **Test suite** (128 pytest, ~95% покрытие критических путей): включает unit-тесты на детерминизм возмущения, симметричность mixing-матрицы, корректность consensus, **аналитические тесты cancellation** для Richardson 4-point ($O(\epsilon^4)$ bias) и 6-point Romberg-Richardson ($O(\epsilon^6)$ bias) на квинтической loss-функции с известными производными.
- **Кросс-платформенная reproducibility**: код работает на Linux + Colab Blackwell (Pro+ RTX PRO 6000), Windows 11 + локальный Blackwell (RTX 5070 Ti), и legacy Turing (RTX 2080) с автоматическим выбором dtype/attention-backend. `notebooks/bootstrap_colab.ipynb` — single-click воспроизведение полной экспериментальной сетки.
- **MLflow tracking**: каждый headline run (Day 1, Day 4, Day 5 grid, R1d, HellaSwag, MathLogicQA) имеет MLflow run ID с полным набором parameters/metrics/artifacts, mirrored в Google Drive. Никаких внешних зависимостей (wandb/Aim) — full self-contained reproducibility.
- **5 ablation/diagnostic скриптов** (`scripts/ablate_*`, `diagnose_*`, `validate_*`, `sweep_*`): полностью composable, каждый принимает `--variant {vanilla, dmezo_n}` и produce JSON + figure в стандартизованных путях. См. `scripts/README.md` для категоризированного индекса, `docs/experiments_summary.md` — chronological table.

4. Теория

4.1 Предположения

- (A1) Гладкость: каждое L_i является ℓ -гладким ($\|\nabla L_i(x) - \nabla L_i(y)\| \leq \ell \|x - y\|$); букву L резервируем за loss-функцией, ℓ — за константой гладкости (как в `docs/theory_rigorous.md`).
- (C2) Ограниченное разнообразие градиентов: $\frac{1}{n} \sum_i \|\nabla L_i(\theta) - \nabla L(\theta)\|^2 \leq \zeta^2$.
- (C3) Ограниченный стохастический шум: $\mathbb{E}_\xi \|\nabla \ell(\theta; \xi) - \nabla L_i(\theta)\|^2 \leq \sigma_b^2$.
- (C5) Эффективный ранг гессиана: $r(H) := \text{tr}(H) / \|H\|_{op} \ll d$ (Malladi 2023 §5).
- (A2 / PL, для Теорем 2 и 3): $\|\nabla L(\theta)\|^2 \geq 2\mu(L(\theta) - L^*) \quad \forall \theta \in \mathbb{R}^d$.

4.2 Набор лемм

Лемма 1 (Nesterov-Spokoiny / Malladi ZO-variance; H-weighted form). В условиях (A1)+(C5) двухточечная ZO-оценка $\hat{g} = \hat{\rho} z$ с $z \sim \mathcal{N}(0, I)$ для любой PSD-матрицы M удовлетворяет H-взвешенной квадратичной оценке

(theory_rigorous.md Лемма 1b'):

$$\mathbb{E}_z[\hat{g}^\top M \hat{g}] \leq \|M\|_{op} \|\nabla L\|^2 (r(M) + 2) + O(\epsilon^2),$$

в частности для $M = H$: $\mathbb{E}_z[\hat{g}^\top H \hat{g}] \leq \ell (r(H) + 2) \|\nabla L\|^2 + O(\epsilon^2)$. Смещение $\|\mathbb{E}[\hat{g}] - \nabla L(\theta)\| \leq \frac{\ell_3}{2} \epsilon^2 (d + 2)$ (Лемма 1a). Замена d на $r(H)$ — ключевая идея Malladi (2023), делающая ZO применимым на масштабе LLM (effective rank $r(H) \ll d$ для overparameterised трансформеров). **Важное уточнение:** сырой евклидов второй момент масштабируется с **полной** размерностью — $\mathbb{E}_z \|\hat{g}\|^2 \leq (d + 2) \|\nabla L\|^2 + O(\epsilon^2)$ (Лемма 1b); послабление effective-rank $r(H)$ применимо только внутри H -взвешенных квадратичных форм, и именно там его использует descent-анализ.

Лемма 2 (ρ -clipping bias-variance). Пусть $\tilde{\rho} = \text{clip}(\hat{\rho}, \pm C)$. Тогда

$$\mathbb{E} \|\tilde{\rho} \cdot z\|^2 \leq \min(\mathbb{E} \|\hat{\rho} \cdot z\|^2, C^2 d),$$

и смещение $|\mathbb{E}[\tilde{\rho}] - \mathbb{E}[\hat{\rho}]| \leq M^2/C$, где $M^2 = \mathbb{E}[\hat{\rho}^2]$. Доказательство: неравенство Маркова на хвосте. ■

Лемма 3 (consensus error в стиле Колосковой; = theory_rigorous.md Лемма 4). Для D -MeZO-N с mixing-матрицей W ($\rho_W < 1$) и моментом β_t (с $\bar{\beta} := \beta_0/2$):

$$\frac{1}{n} \sum_i \|\theta_i^{t+1} - \bar{\theta}_{t+1}\|^2 \leq \frac{\rho_W^2}{(1 - \rho_W)^2} \cdot \frac{\eta^2 (G^2 r(H) + \zeta^2)}{(1 - \bar{\beta})^2}.$$

Помимо mixing-амплифайера $1/(1 - \rho_W)^2$ присутствует momentum-амплифайер $1/(1 - \bar{\beta})^2$: момент усиливает per-round update magnitude и, следовательно, consensus drift. Доказательство: геометрическая прогрессия для степеней mixing-матрицы (Koloskova 2020 Лемма 3) в комбинации с Леммой 2 на per-round update magnitude. ■

Лемма 5 (PL descent с предвзятым SGD; Karimi-Nutini-Schmidt 2016). В условиях (A1)+(A2)+(C2)+(C3) для $\eta \leq 1/(2\ell)$:

$$\mathbb{E}[L(\theta_{t+1}) - L^*] \leq (1 - \eta\mu) \mathbb{E}[L(\theta_t) - L^*] + \frac{\eta^2 \ell \sigma_b^2}{2} + \frac{\eta \zeta^2}{\mu}.$$

(В нотации статьи: σ_b^2 — граница стохастического шума (C3), ζ^2 — граница разнообразия градиентов (C2).

Теорема 2 применяет лемму при более жёстком шаге $\eta \leq 1/(4\ell)$ — запас поглощает ZO-variance фактор Леммы 1 и даёт rate $(1 - \eta\mu/2)$.)

4.3 Теорема 1 — выпуклый случай с моментом

Теорема 1 (сходимость D-MeZO-N, выпуклый случай). Предположим (A1), (C2), (C3), (C5) с выпуклыми L_i . При $\eta = c_1 \cdot \min(1/(\ell r(H)), \sqrt{n/T})$ (потолок $\sqrt{n/T}$, а не $1/\sqrt{T}$, чтобы оптимальный $\eta^* = \sqrt{D_0 n / (C^2 r(H) \ell T)} \sim \sqrt{n/T}$ был допустим для $n > 1$), $\beta_t = \beta \cdot (1 - t/T)$ (линейный спад от β до 0), $\epsilon \leq c_2 / (T^{1/4} \sqrt{r(H) \ell})$, $C \geq 2(\|\nabla L\|_{\max} + \epsilon \ell \sqrt{r(H)})$ итерация D-MeZO-N удовлетворяет:

$$\mathbb{E}[L(\bar{\theta}_T) - L^*] \leq \tilde{O}\left(\sqrt{\frac{\ell \cdot r(H) \cdot D_0}{nT}}\right) + \tilde{O}\left(\frac{\rho_W^2 C^2 r(H)}{(1 - \rho_W)^2 (1 - \bar{\beta})^2 T}\right) + O(\epsilon^2 \ell^2 r(H)).$$

Три слагаемых: стохастическое linear-speedup в n клиентов ($1/\sqrt{nT}$), consensus penalty с mixing-амплифайером $1/(1 - \rho_W)^2$ и momentum-амплифайером $1/(1 - \bar{\beta})^2$ (зануляется для complete graph где $\rho_W = 0$), ZO-bias старшего порядка по ϵ . Здесь $D_0 = \|\bar{\theta}_0 - \theta^*\|^2$; $\tilde{O}$ скрывает ℓ и логарифмические факторы.

Эскиз доказательства. Полное доказательство — docs/theory_rigorous.md §4. В выпуклом случае константы PL μ не существует, поэтому **геометрическая контракция через Ляпунов недопустима**; используется стандартный distance-to-optimum route для выпуклого SGD с усреднением Поляка-Рупперта $\hat{\theta}_T := \frac{1}{T} \sum_t \bar{\theta}_t$.

Шаг 1 (раскрытие расстояния до оптимума). По обновлению consensus-усреднённой итерации:

$$\|\bar{\theta}_{t+1} - \theta^*\|^2 = \|\bar{\theta}_t - \theta^*\|^2 - 2\eta \langle \bar{v}_{t+1}, \bar{\theta}_t - \theta^* \rangle + \eta^2 \|\bar{v}_{t+1}\|^2.$$

Шаг 2 (выпуклость + consensus drift). Берём $\mathbb{E}[\cdot | \mathcal{F}_t]$, выделяем $\mathbb{E}\bar{v}_{t+1} = \nabla L(\bar{\theta}_t) + \xi_t + b_t$ с consensus drift $\xi_t = \frac{1}{n} \sum_i (\nabla L_i(\theta_i^t) - \nabla L_i(\bar{\theta}_t))$, $\|\xi_t\| \leq \ell\sqrt{\Pi_t}$ (ограничен Леммой 3). По **выпуклости** $\langle \nabla L(\bar{\theta}_t), \bar{\theta}_t - \theta^* \rangle \geq L(\bar{\theta}_t) - L^*$ — это заменяет PL-неравенство (никакой $\mu_{\text{eff}} \propto 1/\sqrt{T}$ контракции не вводится).

Шаг 3 (telescoping + Jensen). Суммируем по $t = 0, \dots, T - 1$, делим на $2\eta T$, применяем неравенство Йенсена для $\hat{\theta}_T$:

$$\mathbb{E}[L(\hat{\theta}_T) - L^*] \leq \frac{D_0}{2\eta T} + \underbrace{\text{drift term (I)}}_{\text{Лемма 3}} + \underbrace{\text{variance term (II)}}_{\text{per-client } 1/n},$$

где $D_0 = \|\bar{\theta}_0 - \theta^*\|^2$, (II) $\leq \frac{\eta C^2 r(H) \ell}{2n(1-\beta)^2}$ (federated speedup $1/n$), (I) $\leq \frac{\rho_W^2 C^2 r(H) \ell}{(1-\rho_W)^2 (1-\beta)^2 T} \cdot \text{const}$ (consensus penalty).

Шаг 4 (оптимизация η). Минимизация $\frac{D_0}{2\eta T} + \frac{\eta C^2 r(H) \ell}{2n}$ по $\eta^* = \sqrt{D_0 n / (C^2 r(H) \ell T)}$ даёт rate $\tilde{O}(\sqrt{D_0 C^2 r(H) \ell / (nT)})$ плюс consensus penalty $\tilde{O}(\rho_W^2 C^2 r(H) \ell / ((1 - \rho_W)^2 T))$ плюс ZO-bias $O(\epsilon^2 \ell^2 r(H))$. ■

4.4 Теорема 2 — невыпуклый PL случай (без момента)

Теорема 2 (сходимость D-MeZO, невыпуклый PL, $\beta = 0$). Предположим (A1)+(A2/PL)+(C2)+(C3)+(C5). При $\beta_t \equiv 0$, $\eta \leq 1/(4\ell)$, $\epsilon \leq c/(\ell\sqrt{r(H)T^{1/4}})$, $C \geq 2(\|\nabla L\|_{\max} + \epsilon\ell\sqrt{r(H)})$ итерация удовлетворяет:

$$\mathbb{E}[L(\bar{\theta}_T) - L^*] \leq (1 - \frac{\eta\mu}{2})^T \Delta_0 + \tilde{O}\left(\frac{\eta \ell C^2 r(H)}{\mu n}\right) + \tilde{O}\left(\frac{\eta^2 \rho^2 \ell^2 C^2 r(H)}{\mu (1 - \rho)^2}\right) + O\left(\frac{\epsilon^2 \ell^2 r(H)}{\mu}\right).$$

Линейная сходимость $(1 - \eta\mu/2)^T$ к четырёхчленному шумовому floor: deterministic + linear-speedup stochastic + consensus penalty + ZO bias.

Область применимости. Полное доказательство (theory_rigorous.md §2) проведено для **случая полного графа** ($\rho_W = 0$, точное per-round среднее). Отображённый consensus-penalty член $\tilde{O}(\eta^2 \rho^2 \ell^2 C^2 r(H) / (\mu(1 - \rho)^2))$ для общего mixing $\rho_W > 0$ следует из машинерии Теоремы 1 и приводится здесь как **конъектурное расширение**, строго не выведенное в анализе T2.

Эскиз доказательства. Структура:

Шаг 1 (виртуальная средняя). Вводим виртуальную последовательность $\bar{\theta}_t = \frac{1}{n} \sum_i \theta_i^t$ и виртуальный gradient estimator $\bar{g}_t = \frac{1}{n} \sum_i \tilde{p}_i^t z_{s_i^t}$. По двойной-стохастичности W имеем $\bar{\theta}_{t+1} = \bar{\theta}_t - \eta \bar{g}_t$.

Шаг 2 (bias + variance после federated averaging). Лемма 1 даёт $\|\mathbb{E}[\bar{g}_t] - \nabla L(\bar{\theta}_t)\| \leq \frac{\epsilon^2 \ell}{2} \sqrt{r(H)} + \delta_{\text{consensus}}$, где $\delta_{\text{consensus}}$ — отклонение клиентов от $\bar{\theta}$ (ограничено Леммой 3). Лемма 2 даёт $\mathbb{E}\|\bar{g}_t\|^2 \leq C^2 r(H)/n + \epsilon^2 \ell^2 r(H)$ — фактор $1/n$ из независимости клиентов.

Шаг 3 (PL descent recursion). Применяем PL-descent (Karimi-Nutini-Schmidt 2016; адаптация под biased SGD — Лемма 5) к $\bar{\theta}_t$: после Young-разбиения bias-члена половина PL-контракции уходит на его поглощение, что даёт $\mathbb{E}[L(\bar{\theta}_{t+1}) - L^*] \leq (1 - \eta\mu/2)\mathbb{E}[L(\bar{\theta}_t) - L^*] + \frac{\eta^2 \ell \mathbb{E}\|\bar{g}_t\|^2}{2} + \frac{3\eta\delta^2}{4}$, где δ — bias term (шаги (3)–(5) в theory_rigorous.md §2).

Шаг 4 (telescoping). Стандартное телескопирование recursion $a_{t+1} \leq (1 - \eta\mu/2)a_t + b$ даёт $a_T \leq (1 - \eta\mu/2)^T a_0 + 2b/(\eta\mu)$. Подстановка $b = \frac{3\eta\delta^2}{4} + \frac{\eta^2 C^2 r(H)\ell}{2n}$ даёт boxed-оценку Теоремы 2 с floor $\frac{3\delta^2}{2\mu} + \frac{\eta C^2 r(H)\ell}{\mu n}$ — точное соответствие theory_rigorous.md §2. ■

Теорема 2 строго покрывает поведение нашего рекомендованного варианта D-MeZO-N (R1d) на поздней стадии, где β -расписание затухло $\beta_t \rightarrow 0$ — см. §5.4 для эмпирического соответствия.

4.5 Теорема 3 — PL случай с heavy-ball моментом и β -decay

Теорема 3 (D-MeZO-N convergence под PL + момент). *Предположим (A1)+(A2/PL) и ограничение второго момента под ρ -clipping (A4) $\mathbb{E}\|\tilde{\rho} z\|^2 \leq G^2$ для всех итераций (при clipping на уровне C : $G^2 \leq C^2 r(H) \ell$ в Malladi-refined форме — docs/theory_rigorous.md (A4)). При $\eta \leq (1 - \beta_0^2)/(8\ell)$ и любом расписании $\beta_t \in [0, \beta_0]$ (включая const β_0 и линейный спад $\beta_0 \rightarrow 0$), heavy-ball MeZO-итерация удовлетворяет:*

$$\mathbb{E}[V_T] \leq \left(1 - \frac{3\eta\mu}{2}\right)^T V_0 + \frac{2G^2}{3\mu},$$

где $V_t := (L(\theta_t) - L^*) + (\eta/2)\|v_t\|^2$ — Ляпуновская функция комбинирующая потенциал и кинетику. Поскольку $L(\theta_T) - L^* \leq V_T$, тот же bound выполняется и для loss-компоненты:

$$\mathbb{E}[L(\theta_T) - L^*] \leq \left(1 - \frac{3\eta\mu}{2}\right)^T V_0 + \frac{2G^2}{3\mu}.$$

Эскиз доказательства. Из расширенной (A1)-гладкости в обеих компонентах V_t получаем descent-equation $V_{t+1} \leq V_t - \frac{3\eta}{4}\|\nabla L_t\|^2 - \frac{3\eta(1-\beta_t^2)}{8}\|v_t\|^2 + \eta G^2$ (cross-terms $\pm \eta\beta_t \langle \nabla L_t, v_t \rangle$ из потенциальной и кинетической компонент взаимно сокращаются — именно для этого в V_t выбран множитель $\eta/2$ при кинетике). PL переводит $-\frac{3\eta}{4}\|\nabla L\|^2 \leq -\frac{3\eta\mu}{2}(L - L^*)$, а кинетический член контрактирует со скоростью $\frac{3(1-\beta_t^2)}{4}$. Берём минимум двух скоростей контракции $\alpha_t = \min(3\eta\mu/2, 3(1 - \beta_t^2)/4)$; при $\eta \leq (1 - \beta_0^2)/(8\ell)$ и $\mu \leq 4\ell$ имеем $\alpha_t \equiv 3\eta\mu/2$ независимо от β_t . Геометрическое суммирование $\sum_{k=0}^{\infty} (1 - \alpha)^k \eta G^2 = \eta G^2 / \alpha = 2G^2 / (3\mu)$ даёт neighbourhood. Полное доказательство (шаги (1)–(8), включая явное алгебраическое сокращение cross-terms) — docs/theory_rigorous.md §3. ■

Следствия:

- **Линейная сходимость** к $2G^2/(3\mu)$ -окрестности — rate $(1 - 3\eta\mu/2)$ того же порядка, что у Theorem 2 (plain SGD; константы различаются, см. замечание о несоответствии констант при $\beta = 0$ в theory_rigorous.md §3);

momentum не ускоряет асимптотически (согласуется с Bottou-Curtis-Nocedal 2018 Thm 5.1 и Karimi et al. 2016), но transient acceleration возможна.

- **Rescue mechanism:** при ρ -clipping (A4) $G^2 \leq C^2 r(H) \ell$ — окрестность ограничена; без clipping G^2 unbounded и iterate-sequence разъезжается (см. §5.5 эмпирическое подтверждение).
- **β -decay:** дополнительный кинетический член contraction $3(1 - \beta_t^2)/4$ растёт по мере $\beta_t \rightarrow 0$ — устраняет late-stage drift R1b (§5.4 P4–P5).

4.6 Предсказания vs. эмпирика

Две теоремы дают восемь количественно проверяемых предсказаний; соответствия сведены в Таблицу 1.

#	Предсказание	Теория	Эмпирика	Совпадение
P1	Federated stochastic term ↓ as n растёт	Stochastic term $\propto$ $1/\sqrt{n}$ в T1+T2 (Lemma 1+ Koloskova consensus)	Centralized 0.176 $\rightarrow$ fed 0.130 (ratio 0.74); directional match, не numerical ($1/\sqrt{4} = 0.5$ — theoretical rate, не final- loss ratio)	✓ направление
P2	$\beta = 0.9$ без clip расходится	Variance $1/(1 - \beta^2)$ =5.3× неогр.	Blow-up на R140 (loss 4.1 $\rightarrow$ 16+)	✓
P3	Look-ahead удваивает noise channels	v и в probe location, и в update	Look-ahead NaN на R20 (в 7× быстрее)	✓
P4	ρ -clip + const $\beta \rightarrow$ late drift $\sim \sqrt{t}$	Bounded velocity, biased accumulation	R1b: 0.119 @ R300 $\rightarrow$ 0.225 @ R1000	✓
P5	β -decay убирает drift	$1/(1 - \beta_t)^2 \rightarrow 1$ при $t \rightarrow T$	R1d монотонное убывание	✓
P6	Линейная сходимость $(1 - \eta\mu/2)^T$ (T2)	Геом. спад к noise floor	Ring+IID: 3.56 $\rightarrow$ 0.126	✓
P7	Consensus penalty $\sim$ $\rho^2/(1 - \rho)^2$	Зануляется для complete ($\rho = 0$)	complete $\approx$ ring ($\leq 7\%$ разница)	✓
P8	ZO bias $\sim \epsilon^2$	Старший порядок по возмущению	$\epsilon = 10^{-3} \rightarrow$ bias-член <0.01	✓

5. Эксперименты

5.1 Постановка

Hardware. Google Colab Pro+ с RTX PRO 6000 Blackwell (96 GB). Всё обучение в bfloat16. Один федеративный run на $n = 4$ клиентах $\times$ 1000 раундов на Qwen3.5-4B-Base занимает приблизительно 25–40 мин wall-clock в зависимости от длины контекста (SST-2 vs BoolQ/HellaSwag) и наличия flash-linear-attention fast path. Локальные ablations на меньших моделях (Qwen3-0.6B / 1.7B / Qwen3.5-0.8B) выполнены на RTX 5070 Ti Blackwell (16 GB).

Модели. Qwen3-4B (стандартный трансформер с full attention; ~8 GB FP16) для Day 4 baseline; Qwen3.5-4B-Base (гибридная linear/full-attention V-L модель; 24-слойный ViT заморожен через loader модели, MeZO возмущает только 426 trainable групп параметров text decoder) для всех последующих экспериментов.

Задачи. GLUE / SST-2 (бинарная сентимент-классификация, prompt-completion framing по Malladi 2023) — основная задача. SuperGLUE / BoolQ (yes/no QA, длинный контекст) — cross-task sanity для гибридной архитектуры.

Канонические гиперпараметры. Подобраны через LR ablation на Day 1: $\eta = 3 \cdot 10^{-7}$, $\epsilon = 10^{-3}$, weight_decay = 0, batch_size = 8, max_length = 256 (SST-2) / 512 (BoolQ). Consensus mode: weight_avg (дважды-стохастический по Koloskova). Число клиентов: $n = 4$. Train pool: 2000 примеров, разбитых по клиентам. Eval pool: 200 примеров (отдельный split). Seeds: 42 и 43.

5.2 Федеративная сетка (multi-seed)

Оцениваем D-MeZO без момента на сетке 2×2 топологии (complete, ring) $\times$ распределения (IID, Dirichlet($\alpha = 0.5$); неоднородное партиционирование по Hsu et al. 2019), с обоими seed-ами 42 и 43. **Caveat nro seed variance:** Dirichlet partition seeded по тому же seed что и алгоритм, и реализации существенно различаются (s42: размеры клиентов {340, 1488, 167, 5} с extreme imbalance — один клиент имеет всего 5 примеров; s43: {1322, 195, 388, 95} с более мягким distribution). Поэтому 2-seed «half-range» включает BOTH алгоритмическую стохастичку AND шум partition realization — partition-variance вероятно дальше доминирует. Идеальный multi-seed setup фиксировал бы partition и варьировал только seed алгоритма; в текущей реализации этого не сделано. Воспринимать reported $\pm$ интервалы как **верхнюю** оценку seed-variance.

Figure 1. Day 5 grid — federated D-MeZO trajectories per cell
(Qwen3.5-4B-Base / SST-2 / 4 clients / 1000 rounds; 2 seeds + centralized reference)




Рисунок 2. Per-cell trajectories Day-5 федеративной сетки на Qwen3.5-4B-Base / SST-2. Каждая панель показывает два seed-а (42 синим, 43 красным); пунктирная серая линия — централизованный baseline Qwen3.5. Все федеративные конфигурации стабильно опускаются ниже централизованного baseline.

Среднее по seed-ам с half-range в роли консервативной error bar сведено в Таблицу 2:

Конфигурация	Final eval (среднее $\pm$ range/2)	Accuracy (среднее, %)	vs. centralized 0.1762
complete + IID	0.1348 $\pm$ 0.0051	96.56%	−23.5%
complete + Dir($\alpha = 0.5$)	0.1507 $\pm$ 0.0089	95.00%	−14.5%
ring + IID	0.1271 $\pm$ 0.0014	97.81% ★ best	−27.9%
ring + Dir($\alpha = 0.5$)	0.1402 $\pm$ 0.0029	95.63%	−20.4%
centralized (reference)	0.1762 (n=1)	95.63%	—
R1d (D-MeZO-N) на worst cell	0.1291 (single seed)	95.63%	−26.7%

Figure 3. Federated D-MeZO consistently beats centralized MeZO on Qwen3.5-4B-Base / SST-2




Рисунок 3. (a) Final eval loss каждой федеративной конфигурации (среднее $\pm$ range по 2 seed-ам) против централизованного MeZO baseline. Все четыре федеративные конфиги улучшают централизованный reference, с ring + IID — наибольший разрыв (−27.9%). (b) Сравнение финальной ассигасу; все конфигурации кучкуются в пределах 3 п.п., наивысшее среднее у ring + IID (97.8%).

5.3 Почему federated превосходит centralized? (механизм P1)

Эмпирическое соотношение $0.1271/0.1762 = 0.722$ согласуется по направлению с федеративным variance reduction — федеративные клиенты с независимыми z_i выигрывают относительно централизованного MeZO. Мы **не утверждаем** количественное совпадение с предсказанием $1/\sqrt{n} = 0.5$ из Теоремы 1: разница $0.722 \neq 0.5$ остаётся необъяснённой (вероятно, зависит от $r(H)$ -зависимого константного множителя), и прямого переноса теоретического rate на финальный loss-ratio нет. Механизм: когда n клиентов независимо делают MeZO-замер своим собственным seed-ом s_i и направлением z_{s_i} , consensus-усреднение даёт несмещённое среднее n независимых unit-direction замеров. Стандартный анализ variance reduction (дисперсия $\div n$) показывает, что weight_avg consensus фактически делает параллельное multi-direction MeZO при том же бюджете forward-passes, что и централизованный single-direction MeZO. Это «бесплатная выгода» для федеративного обучения в ZO-режиме — обратная обычной FL-формулировке, где федеративный setup воспринимается как cost-paying. Количественное совпадение с теоретическим $1/\sqrt{n}$ -rate оставляем для будущей работы.

5.4 Nesterov ablation: фазовая диаграмма на worst cell

Изолируем worst Day-5 ячейку (ring + Dir($\alpha = 0.5$)) и прогоняем серию вариантов момента при seed=42 для bit-exact ablation.

Figure 2. Nesterov-MeZO phase diagram on worst Day 5 cell (ring(4) + Dir($\alpha=0.5$))
All runs at seed=42 for bit-exact ablation; ρ -clip + β -decay required for stable acceleration




Рисунок 4. Фазовая диаграмма вариантов Nesterov-MeZO на самой сложной федеративной ячейке. $\beta = 0.9$ без clip (фиолетовый) расходится на раунде R140 из-за noise-amplified velocity; loose clipping при $C = 200$ (оранжевый) предотвращает мгновенный blow-up, но медленно расходится к R500; tight clipping при $C = 50$ с постоянным $\beta = 0.9$ (R1b, красный) даёт $3\times$ early speedup, но momentum overshoot вызывает late drift после R300; рекомендованный linear β -decay $0.9 \rightarrow 0$ с $C = 50$ (R1d, зелёный) даёт монотонное убывание на всём горизонте.

Фазовая диаграмма содержит четыре чётко разделённых региона, каждый количественно предсказанный Теоремой 1 (через variance amplifier $1/(1 - \beta_t)^2$):

- **Регион А** (без clip, высокий β): катастрофический blow-up на $R \approx 140$. Variance amplifier $5.3\times$ ZO-variance неограничен.
- **Регион В** (loose clipping $C = 200$, высокий β): ограниченные выбросы, но velocity buffer накапливает sub-clip шум; trajectory slow-diverges к R500.
- **Регион С** (tight clipping $C = 50$, постоянный β): velocity ограничен; early-stage $3\times$ speedup; late-stage momentum overshoot создаёт $\sqrt{t}$ drift после R300.
- **Регион D** (tight clipping $C = 50$, β -decay $0.9 \rightarrow 0$): velocity ограничен И amplifier $\rightarrow 1$ при $t \rightarrow T$; монотонное убывание; final 0.1291 превосходит control 0.1373 на 6.0%.

Figure 4. D-MeZO-N (R1d) detailed trajectory — β -decay produces monotonic descent
Final 0.129 beats vanilla 0.137 by 6%; β linearly decays $0.9 \rightarrow 0$ over $T=1000$




Рисунок 5. Детальная траектория D-MeZO-N (R1d) против no-Nesterov control на worst cell. Eval loss на левой оси (log scale); β -расписание $\beta(t) = 0.9 \cdot (1 - t/T)$ наложено красным на правой оси. Траектория R1d строго монотонно убывает в каждой контрольной точке, заканчиваясь на 0.1291 против control 0.1373.

5.5 Cross-task validation: HellaSwag (4-way commonsense reasoning)

Дополнительно тестируем D-MeZO-N на **HellaSwag** (Zellers et al. 2019) — 4-way commonsense reasoning. Это существенно сложнее SST-2/BoolQ, потому что концовки многотокенные и требуют world-knowledge inference, а не лексических сигналов. Setup: Qwen3-4B (full-attention transformer, bf16, Apache 2.0), $\eta = 3 \cdot 10^{-7}$, $\epsilon = 10^{-3}$, 1000 шагов/раундов, 2000 train examples, 200 eval examples, seed=42.

Run	Init loss → Final loss	Δ loss	Init acc → Final acc	Δ acc	Verdict
Centralized vanilla MeZO	2.5691 → 2.7112	+5.5%	0.6625 → 0.6375	-2.50pp ($\approx 0.74\sigma$)	loss diverges
Federated D-MeZO-N v1 (4c complete IID, β -decay $0.9 \rightarrow 0$, ρ -clip $C = 50$)	2.5691 → 2.4959	-2.85%	0.6625 → 0.7000	+3.75pp ($\approx 1.1\sigma$)	loss converges
Δ federated vs. centralized	-7.9% relative loss	—	+6.25pp absolute acc	—	—

Ключевые находки:

- Vanilla MeZO теряет сходимость по loss на HellaSwag** — eval loss растёт монотонно от R200, модель теряет 2.5 pp accuracy к R1000. Caveat: 2.5pp при SE на 200-example acc $\approx \pm 3.4pp$ — accuracy-drop сам по себе **внутри noise band** ($\sim 0.74\sigma$); более убедительное свидетельство расходимости — это monotonic loss drift +5.5%, что **за пределами noise band** на loss-метрике. Это новый negative finding: vanilla MeZO **не всегда сходится** по loss на hard reasoning task'ах, даже centralized. Наблюдённые $|\hat{\rho}|$ значения достигают пика +159 (R360) — без clipping эти выбросы кумулятивно дрейфят модель.

2. **D-MeZO-N v1 спасает** — та же модель, та же задача, те же гиперпараметры кроме $\rho\text{-clip}=50$ и $\beta\text{-decay}$ $0.9 \rightarrow 0$ дают монотонное убывание (loss $2.5691 \rightarrow 2.4959$) и прирост точности ($0.6625 \rightarrow 0.7000$, best 0.7000 достигнут на R800). Финальная фаза $\beta \rightarrow 0$ даёт малые осцилляции (R900 acc= 0.6875 , R1000 acc= 0.7000) — согласуется с $\beta\text{-decay}$ -следствием Теоремы 3 (§4.5): $\|v_T\|^2 \rightarrow G^2$.

3. **Federated > centralized** (single-seed evidence). Federated D-MeZO-N даёт наблюдаемое **+6.25 pp accuracy** над centralized vanilla на одной и той же связке Qwen3-4B / HellaSwag (single seed, eval SE $\approx \pm 0.04$ на 100-example pool). Эффект-размер выше noise band, но требует multi-seed re-validation (см. §6.9). Два правдоподобных усиливающих механизма, согласованных с Theorem 2 (§4.4): (a) $\rho\text{-clipping} + \beta\text{-decay}$ стабилизация (rescue regime), (b) усреднение независимых $z\text{-direction}$ probes по $n = 4$ клиентам ($1/n$ variance-floor reduction).

Это **напрямую валидирует Theorem 3**: под (A4) $\rho\text{-clipping}$ при $C = 50$, variance bound $G^2 \leq C^2 r(H) \ell$ выполняется, и iterate sequence сходится линейно к $2G^2/(3\mu)$ -окрестности. Без clipping (centralized vanilla) G^2 не bounded и окрестность разъезжается — эмпирически подтверждено.

5.6 Cross-lingual + cross-architecture: MathLogicQA на Qwen3.5-4B-Base — 3-seed paired validation

Для закрытия universality claim дополнительно тестируем на **MathLogicQA** (часть MERA, ai-forever/MERA) — 4-way symbolic logic + arithmetic reasoning **на русском**. Pair’им с **Qwen3.5-4B-Base** (hybrid linear-attention V-L из §3.1) — это первый known MeZO test на (hybrid linear-attn) $\times$ (русский reasoning).

Data pool: MERA train (680 labelled examples); internal 80/20 split $\rightarrow$ 544 train / 136 val, subsample до 500 train / 100 eval. Setup: 4 clients complete IID / 1000 rounds / $\text{lr}=3\text{e-}7$ / $\epsilon=1\text{e-}3$. **Multi-seed paired validation на 3 seeds $\times$ 5 variants = 15 cells, ~12 часов compute (Colab Blackwell).**

5.6.1 Эволюция recipe от v1 (single-seed false positive) к v2 (multi-seed validated)

Изначальный single-seed Day 8 R1d hint (“D-MeZO-N v1 fixed $C=50$ beats vanilla 6.0%”) **multi-seed falsified**: на 3 seeds $\times$ 1000 раундов **v1 robustly worse than vanilla** (3/3 same direction, +7.0% loss). Diagnosis: на Qwen3.5-4B-Base median $|\hat{\rho}| \approx 180$, fixed $C = 50$ слишком tight — обрезает большую часть полезного signal. Adaptive формулировка (B1) tracking running 95-percentile решает эту проблему. Multi-seed дополнительно выявил accuracy paradox B1 alone — добавили drift-reset (B5), получили D-MeZO-N v2 = **combo (B1+B5)**.

5.6.2 Финальные 3-seed paired результаты

Соглашение о std. Везде в статье « $\pm$ » обозначает популяционное стандартное отклонение (ddof = 0, знаменатель $n = 3$ по seed-ам); выборочное std (ddof = 1) примерно на 22% больше и не меняет ни одного утверждения о направлении эффекта.

Variant	s=42 loss/acc	s=43 loss/acc	s=44 loss/acc	Mean $\pm$ std loss	Mean $\pm$ std acc	Δ vs vanilla	Direction (3 seeds)
vanilla MeZO	1.3747 / 0.38	1.3432 / 0.36	1.3863 / 0.39	1.3681 $\pm$ 0.018	0.377 $\pm$ 0.012	reference	—
D-MeZO-N v1 (fixed $C = 50$)	1.4598 / 0.38	1.4569 / 0.36	1.4735 / 0.39	1.4634 $\pm$ 0.007	0.377 $\pm$ 0.012	+7.0% loss / 0pp acc	3/3 worse (falsified)
Drift-only (B5, 53 resets)	1.4608 / 0.38	1.4531 / 0.36	1.4537 / 0.39	1.4559 $\pm$ 0.003	0.377 $\pm$ 0.012	+6.4% loss / 0pp acc	3/3 worse (falsified)
Adaptive_clip (B1 alone)	1.2691 / 0.41	1.3135 / 0.33	1.3135 / 0.43	1.2987 $\pm$ 0.021	0.390 $\pm$ 0.043	−5.1% loss / +1.3pp	3/3 wins loss , acc seed-specific
D-MeZO-N v2 = combo (B1+B5, 54 resets) ★	1.2790 / 0.37	1.2951 / 0.44	1.3036 / 0.39	1.2926 $\pm$ 0.010	0.400 $\pm$ 0.029	−5.5% loss / +2.3pp acc	3/3 wins loss

Главный результат: D-MeZO-N v2 = combo (B1 adaptive_clip + B5 drift-reset) **устойчиво превосходит vanilla MeZO** на 3-seed paired validation: - **Loss:** 3/3 same direction ($\Delta \in \{-7.0\%, -3.6\%, -6.0\%\}$, mean = −5.5%) - **Accuracy:** mean +2.3pp (per-seed $\Delta \in \{-1\text{pp}, +8\text{pp}, 0\text{pp}\}$ — никогда существенно не теряет) - **Наименьший std loss среди вариантов, улучшающих vanilla** (0.010 vs B1 alone 0.021; сам vanilla 0.018) — additional robustness metric. (Drift-only имеет ещё меньший std loss 0.0035, но это артефакт его равномерного «застревания» на худшем loss +6.4%, а не стабильность хорошего решения.)

5.6.3 Mechanism — почему combo > B1 alone

Drift-reset fires 54 раза total на 3 seeds (≈ 18 per seed). На s=43 без него adaptive_clip drifts up после R600 (trajectory R600=1.309 $\rightarrow$ R1000=1.313); combo держит ниже (1.286 $\rightarrow$ 1.295) благодаря 18 resets. На s=44 similar pattern (combo 1.304 vs adaptive 1.313). B5 surgically обнуляет v_t при `eval_loss > rolling_min + 0.1` — предотвращает momentum overshoot.

5.6.4 Cross-task / cross-architecture summary

Task / Model	Vanilla	D-MeZO-N v2	Perim	Validation
SST-2 (Day 8 R1d, Qwen3.5-4B-Base)	converges	hint of 6.0% speedup	acceleration (transient)	n=1, tentative
HellaSwag (Qwen3-4B)	diverges (−2.5pp acc)	converges (+3.75pp)	rescue	n=1, tentative , multi-seed pending
MathLogicQA (Qwen3.5-4B-Base)	сходится (1.368 $\pm$ 0.018)	выигрывает 1.293 $\pm$ 0.010	безопасное отслеживание + выигрыш	n=3 paired, ROBUST ★

Headline — convergent task multi-seed validated **3-seed paired direction consistency**. HellaSwag rescue remains **tentative** (single-seed) — multi-seed validation планируется как follow-up (script готов в `scripts/validate_dmezo_n_rescue_multiseed_federated.py`).




Рисунок 6. Cross-domain траектории, иллюстрирующие два режима D-MeZO-N. (a) HellaSwag на Qwen3-4B: centralized vanilla MeZO дрейфит вверх от R200 (final loss +5.5% относительно init, accuracy -2.5pp), а federated D-MeZO-N v1 (β -decay 0.9 $\rightarrow$ 0 + ρ -clip=50) монотонно убывает (final loss -2.85%, accuracy +3.75pp). (b) MathLogicQA на Qwen3.5-4B-Base: vanilla MeZO уже сходится (loss -49.7%); D-MeZO-N трекает близко (loss -46.8%) с небольшим асс-приростом (+1.25pp final / +3.75pp peak @R500; single-seed s42 — позднее фальсифицировано multi-seed, см. §5.6.2). Один рецепт, два качественно разных режима сходимости.




Рисунок 7. Cross-task summary: улучшение D-MeZO-N v1 относительно centralized vanilla MeZO по трём доменам задач. SST-2 (Day 8 R1d, single-seed): +6.0% loss reduction. HellaSwag (§5.5): +6.25pp accuracy (rescue regime — vanilla расходится). MathLogicQA (§5.6): +1.25pp accuracy (single-seed; позднее фальсифицировано multi-seed валидацией — §5.6.2). Все три числа — single-seed результаты v1-рецепта (β -decay 0.9 $\rightarrow$ 0 + ρ -clip=50) до multi-seed валидации; актуальный headline см. §5.6.2 (v2 combo).

5.7 Воспроизводимость

Все эксперименты воспроизводимы из публичного репозитория. Репо содержит:

- **Код:** `src/dmezo/` (~2.5K LOC) с MeZO-примитивами, federated simulator, partition utilities, вариантами Нестерова с ρ -clipping и β -schedule.
- **Тесты:** 128/128 pytest проходят. Покрытие: детерминизм возмущения, свойства mixing-матрицы, корректность simulator consensus, статистика partition, classification accuracy, ρ -clipping, β -schedule, Richardson 4-pt и 6-pt finite-diff cancellation.
- **Конфиги:** `configs/*.yaml` — один на эксперимент, Hydra-loadable.
- **Notebooks:** `notebooks/run_finals.ipynb` — single-click воспроизведение полной multi-seed сетки + R1d + centralized baseline на Colab Pro+.
- **MLflow run IDs** (Drive-mirrored) для каждой числовой величины в Таблицах 1–2 и на рисунках раздела §5.
- **Технотчёт** `docs/theory_rigorous.md` с полными доказательствами Теорем 1–4.

6. Обсуждение

6.1 Почему ring $\leq$ complete на ZO-режиме? (C3)

Контр-интуитивный результат: на обоих partition-режимах ring ($\rho(W) = 0.333$) стабильно сравним или превосходит complete ($\rho(W) = 0$). В обычном first-order федеративном обучении complete должен доминировать, поскольку даёт точное per-round среднее. В ZO-режиме, однако, очень высокая per-step дисперсия $\hat{\rho}$ означает, что более медленное consensus-усреднение может играть роль неявного регуляризатора — каждый клиент интегрирует свой локальный шум за несколько раундов, прежде чем он распространится к соседям, сглаживая эффективную траекторию. Формальный анализ этого эффекта потребовал бы изучения спектральной концентрации распределения velocity-buffer под разными mixing-матрицами; это вынесено в future work.

6.2 Почему наивный Нестеров несовместим с ZO?

Двухканальная noise-структура look-ahead Нестерова (probe-location и update-direction оба зависят от v_i) компаундирует variance-amplification: look-ahead позиция $\theta + \beta v_i$ сама по себе является зашумлённым сдвигом, и замер там даёт $\hat{\rho}$ -оценку с дисперсией, масштабирующейся как квадрат локального гессияна умноженный на $\|v_i\|^2$. При $\beta = 0.9$ look-ahead вариант расходится в $7\times$ быстрее heavy-ball варианта (R20 vs. R140), что подтверждает dual-channel механизм. Мы гипотезируем, что variance-reduced ZO-оценки (multi-direction SPSA, усредняющие K направлений на шаг) могут восстановить хорошие свойства look-ahead Нестерова; проверка этого оставлена для follow-up работы.

6.3 Практический рецепт

На основе наших экспериментов рекомендуем следующий deployment-рецепт для D-MeZO-N v2. **Важно:** фиксированный $C = 50$ из v1 был **мультид-фальсифицирован** (3/3 хуже vanilla, §5.6.1) — рекомендуется только адаптивный клип. Полный набор гиперпараметров — в §6.11.3; кратко:

- $\eta = 3 \cdot 10^{-7}$ (default Princeton MeZO, скорректированный по нашему LR ablation).
- $\epsilon = 10^{-3}$ (default Malladi 2023; cross-arch подтверждён в §6.7).
- **Adaptive ρ -clipping** $C_t = 1.3 \cdot \text{quantile}_{0.95}(\{|\hat{\rho}|\}_{\text{последние 50 раундов}})$ (B1, §6.11.1) вместо фиксированного C ; data-driven порог на Qwen3.5-4B-Base оказывается в $3\text{--}6\times$ больше $C = 50$.
- **Drift-reset** (B5): зануление velocity-буфера при росте eval-loss > 0.1 на окне 50 раундов.
- Линейное β -расписание $\beta_t = 0.9 \cdot (1 - t/T)$.
- Дважды-стохастическая mixing-матрица W . Кольцо или complete-топология дают близкие результаты при $n = 4$.
- Multi-seed (≥ 3) для paper-grade оценки дисперсии; в headline-валидации (§5.6.2) использовано 3 seed-a.

6.4 Batch-size variance scaling: эмпирически $1/\sqrt{B}$ НЕ выполняется

Стандартное CLT предсказывает, что дисперсия per-step ρ -оценки уменьшается как $1/B$ с размером mini-batch, т.е. $\text{std} \propto 1/\sqrt{B}$. Мы проверили это эмпирически на Qwen3-0.6B / SST-2 с фиксированным z на 100 случайных батчах для каждого $B \in \{1, 2, 4, 8, 16, 32\}$ (Рисунок 8). Наблюдаемая std **выходит на плато** при $B \geq 8$ с ratio (observed / CLT-expected) растущим от $1.55\times$ ($B=2$) до $3.43\times$ ($B=32$). Это означает, что доминантный источник шума в MeZO — это **не** sampling данных, а **выбор направления** z (и второстепенно — low-precision арифметика в разности $L_+ - L_-$). Следовательно, увеличение batch size за пределы ~ 8 не даёт пользы, тогда как K -direction averaging по свежим

z_k **ДЕЙСТВИТЕЛЬНО** снижает variance (см. `tests/test_md_mezo.py::TestKDirectionVarianceReduction`). Это обосновывает наш small-batch ($B=4-8$) рецепт и мотивирует multi-direction расширения над batch-scaling.




Рисунок 8. Эмпирическое распределение MeZO projected-gradient оценки $\hat{\rho}$ для фиксированного направления возмущения z при mini-batch размерах $B \in \{1, 2, 4, 8, 16, 32\}$. Setup: Qwen3-0.6B fp16 / SST-2 / $\epsilon=10^{-3}$ / 100 случайных батчей на B . CLT-предсказание $\text{std} \propto 1/\sqrt{B}$ НЕ выполняется: std выходит на плато при $B \geq 8$ (ratio observed/expected растёт от $1.55\times$ при $B=2$ до $3.43\times$ при $B=32$). Доминантный источник дисперсии — это выбор z , а не sampling данных, что мотивирует multi-direction (вариация z) поверх batch-scaling для variance reduction в MeZO. **Caveat:** видимый shift mean-значений между панелями (отрицательные для $B \leq 4$, положительные для $B \geq 8$) — артефакт sampling design: единый `rng` advances последовательно через `for B in batch_sizes`, поэтому разные B видят независимые подмножества SST-2 с разным class-balance, что даёт разные empirical gradients $\langle \nabla L_{\text{subset}}, z \rangle$. Это не свойство MeZO и не влияет на главный finding (within-B variance saturation), который зависит только от intra-panel дисперсии.

6.5 Reviewer response: multi-direction SPSA (MD-D-MeZO-N)

Внешний reviewer предложил заменить ρ -clipping на K -direction SPSA averaging (variance reduction в источнике, а не симптоме) и использовать true look-ahead Нестерова для достижения оптимального rate $O(1/T^2)$. Мы эмпирически проверили это на worst Day 5 cell (ring + Dir(0.5) Qwen3.5-4B-Base, идентично R1d) с $K = 3$. Результат: final eval loss **0.1828 ($K=3$) vs 0.1291 ($K=1$ R1d)** — **+41.6% ХУЖЕ по loss** — но final accuracy **0.9688 vs 0.9563** — **+1.25pp ЛУЧШЕ по acc**. K -direction averaging работает как **generalization regularizer**, а не pure speedup. Claim про “оптимальный $O(1/T^2)$ ” — фальсифицирован эмпирически; теоретически он также **некорректен** для стохастического NAG при $\sigma > 0$ (Bottou-Curtis-Nocedal 2018, Theorem 5.1). ρ -clipping и multi-direction — **дополняют, не заменяют** друг друга: идеальный практик использует оба (per-direction clip с порогом $C \cdot \sqrt{K}$). Compute cost: **$2K$ forwards/шаг** (vs 2 baseline); $1.84\times$ wall-clock на $K = 3$ за счёт амортизации consensus-overhead.

6.6 Выбор constant learning rate

Классическая SPSA-литература (Spall 1992, §3.2) предписывает harmonic decay $\eta_t = a/(t + A)^\alpha$ с $\alpha \approx 0.602$ для гарантии сходимости к истинному оптимуму θ^* . Мы следуем Princeton MeZO (Malladi 2023) и используем **constant η** , что под Theorem 3 даёт сходимость только к **noise-окрестности** радиуса $O(G^2/\mu)$, не к θ^* . Для fine-tuning LLM это **приемлемо** — нам нужна “достаточно хорошая” параметризация, не точная сходимость — и constant η даёт более быстрый initial descent ($O(1/T)$) чем harmonic ($O(1/T^{0.602})$). Schedule sweep по {constant, harmonic, cosine} прямолинейно добавляется как future ablation; codebase предоставляет `MeZOConfig.lr_schedule` для этого.

6.7 ε -autotuner: bias-variance proxy не работает в fp16

Princeton MeZO использует $\varepsilon = 10^{-3}$ как default. Гипотеза: в fp16 catastrophic cancellation в разности $L_+ - L_-$ инфлирует variance ρ -оценщика при малом ε , и autotuning мог бы найти ε^* существенно больше 10^{-3} с меньшей дисперсией. Мы построили warmup-autotuner (scripts/diagnose_eps_warmup.py), который на 30 свежих z -зондах для каждого $\varepsilon \in \{10^{-5}, \dots, 1.0\}$ оценивает variance proxy $\text{Var}[\hat{\rho}]$ и bias proxy $|E[z^\top H z]|$ через $\Delta_2 = (L_+ + L_- - 2L_0)/\varepsilon^2$, выбирая ε^* минимизирующий нормализованную сумму. На cross-arch sweep (Qwen3-0.6B full-attn + Qwen3.5-0.8B hybrid) autotuner возвращает $\varepsilon^* \in \{10^{-1}, 3 \cdot 10^{-1}\}$ (на 2–3 порядка больше Princeton default), при этом $\text{std}[\hat{\rho}]$ меньше в 4–7 $\times$, что выглядит как ясный win (Рисунок 9, верхний ряд).

Однако короткий downstream-sweep (100 шагов MeZO, $\eta = 3 \cdot 10^{-7}$, общие батчи + z -сиды для всех ε) **РАЗВОРАЧИВАЕТ** этот вывод (Рисунок 9, нижний ряд). На Qwen3-0.6B drop eval-loss за 100 шагов: $\varepsilon = 10^{-3} \rightarrow -60.8\%$, $\varepsilon = 3 \cdot 10^{-2} \rightarrow -17.4\%$, $\varepsilon = 10^{-1} \rightarrow -13.9\%$. На Qwen3.5-0.8B картина ещё резче: $\varepsilon = 10^{-3} \rightarrow -63.1\%$, тогда как все autotuner-выборы **активно увеличивают loss** (+5.3%, +14.7%, +19.3% соответственно). Princeton default выигрывает в 3–6 $\times$.

Диагноз: наш “bias proxy” $|E[z^\top H z]|$ оценивает trace гессиана $\text{tr}(H)$, а не bias MeZO-оценщика, который масштабируется как $\varepsilon^2 \cdot E[z^\top \nabla^3 L \cdot z z]$ (третий член Тейлора, **невидимый** для Δ_2). При большем ε variance действительно меньше, но third-order bias доминирует и направление оценки систематически неверно. Под классической SGD-теорией unbiased-but-noisy оценщик усредняется до правильного направления за много шагов, тогда как biased estimator — нет. Параллельная находка с §6.4 (CLT для batch-size также эмпирически не выполняется): **наивные variance-reduction proxy в MeZO ненадёжны**, и единственный честный селектор ε — это короткий downstream-sweep (что мы здесь и применили ad hoc). Practical recommendation: **придерживаться Princeton $\varepsilon = 10^{-3}$ в fp16**.




Рисунок 9. Cross-arch contradiction между autotuner и downstream training. Верхний ряд: warmup-autotuner $J(\epsilon)$ -score (нормализованная сумма bias + variance proxies) минимизируется при $\epsilon^* \in \{10^{-1}, 3 \cdot 10^{-1}\}$ для обеих архитектур; крестиками отмечены ϵ при которых forward pass даёт NaN (Taylor-3 nonlinearity cliff), пунктиром — Princeton default $\epsilon=10^{-3}$ и autotuner-выбор ϵ^* . Нижний ряд: downstream MeZO training на 100 шагов ($\text{lr}=3 \cdot 10^{-7}$, общие батчи + z-сиды), eval-loss at clean θ на fixed batch. Princeton $\epsilon=10^{-3}$ даёт drop -60.8% (Qwen3-0.6B) и -63.1% (Qwen3.5-0.8B); autotuner-выборы дают только $-13.9\% \dots -17.4\%$ на full-attn и **активно растят loss** ($+5.3\% \dots +19.3\%$) на hybrid. Bias-proxy autotuner’a оценивает $\text{tr}(H)$, а не $\text{gradient bias} \propto \epsilon^2 \cdot \nabla^3 L$, поэтому variance-reduction за счёт большего ϵ обменивается на доминирующий third-order bias и направление оценки систематически неверно.

$\epsilon(t)$ scheduling: не спасает. Естественный follow-up — может ли time-varying $\epsilon(t)$ совместить low-variance warmup (большой ϵ) с low-bias refinement (малый ϵ)? Мы проверили пять log-линейных schedule на обеих архитектурах (`scripts/ablate_eps_schedule.py`, 100 шагов, общие батчи + z-сиды): $\text{const-}10^{-3}$ (Princeton baseline), $10^{-3} \rightarrow 10^{-4}$ (классический Spall-decay), $10^{-2} \rightarrow 10^{-3}$ и $3 \cdot 10^{-2} \rightarrow 10^{-3}$ (warmup-to-refine), и $10^{-3} \rightarrow 10^{-2}$ (anti-schedule control). Cross-arch результат (Рисунок 10): warmup-style schedules **систематически проигрывают** $\text{const } 10^{-3}$ — drop $+44.7\%$ (mild) и $+42.8\%$ (aggressive) на full-attn, $+31.2\%$ и $+18.7\%$ на hybrid (vs $+60.8\%$ и $+63.5\%$ для const). Anti-schedule grow $10^{-3} \rightarrow 10^{-2}$ тоже проигрывает ($+48.1\%$ / $+14.2\%$). **Качественный механизм:** в первые 20–30 шагов происходит самый резкий descent, и biased gradient updates с большого ϵ в этой фазе **не восстанавливаются** — траектория попадает на suboptimal manifold, с которого refinement малым ϵ уже не выводит за 100 шагов. Дополнительный finding: refinement **ниже** Princeton ($10^{-3} \rightarrow 10^{-4}$) на full-attn практически tied с const ($+59.8\%$ vs $+60.8\%$), но на hybrid **превосходит** Princeton на 4.2pp ($+67.7\%$ vs $+63.5\%$) — на hybrid linear-attention классический Spall-decay даёт малый, но воспроизводимый выигрыш. Итого: для **fp16 MeZO рецепт** — **стартовать в $\epsilon = 10^{-3}$** ; если хочется refinement, decay должен идти **вниз** от Princeton, никогда не сверху.




Рисунок 10. Cross-arch $\varepsilon(t)$ schedule ablation. Слева: Qwen3-0.6B (full-attention). Справа: Qwen3.5-0.8B (hybrid linear-attention). Пять schedule: const- 10^{-3} (синий), decay $10^{-3} \rightarrow 10^{-4}$ (зелёный), decay $10^{-2} \rightarrow 10^{-3}$ (оранжевый), decay $3 \cdot 10^{-2} \rightarrow 10^{-3}$ (красный), grow $10^{-3} \rightarrow 10^{-2}$ (фиолетовый). На обеих архитектурах все warmup-style и grow schedules заметно проигрывают const $\varepsilon=10^{-3}$ из-за невозвратной biased descent в первые 20–30 шагов. Классический Spall-decay $10^{-3} \rightarrow 10^{-4}$ — единственная схема, способная превзойти const, и только на hybrid (+4.2pp). Practical recipe: стартовать в Princeton $\varepsilon=10^{-3}$; декау только вниз.

6.8 Boundary-condition study: joint $\text{lr} \times \varepsilon \times \text{variant}$ sweep на short-horizon reasoning task

Чтобы установить **границы применимости** §5.5 D-MeZO-N rescue эффекта, мы провели exploratory $4 \times 3 \times 2 = 24$ -cell sweep на **намеренно урезанной** комбинации: Qwen3.5-4B-Base hybrid (другая архитектура, чем §5.5), HellaSwag, **500 шагов** (vs 1000+ rounds в §5.5). Grid: $\eta \in \{10^{-7}, 3 \cdot 10^{-7}, 10^{-6}, 3 \cdot 10^{-6}\} \times \text{schedule} \in \{\text{const } 10^{-3}, \text{decay } 10^{-3} \rightarrow 10^{-4}, \text{warmup } 10^{-2} \rightarrow 10^{-3}\} \times \text{variant} \in \{\text{vanilla}, \text{D-MeZO-N с } C = 50, \beta_0 = 0.9 \rightarrow \beta_T = 0\}$. Eval каждые 50 шагов на 100-example HellaSwag validation (single seed = 42). Compute ≈ 3 часа на Blackwell.

η	schedule	vanilla $\Delta L\%$	D-MeZO-N $\Delta L\%$	vanilla acc / D-MeZO-N acc
10^{-7}	const 10^{-3}	−1.0%	−0.7%	0.71 / 0.71
$3 \cdot 10^{-7}$	const 10^{-3}	−0.7%	+0.3%	0.69 / 0.69
10^{-6}	const 10^{-3}	+1.0%	−4.5%	0.67 / 0.63
10^{-6}	decay $10^{-3} \rightarrow 10^{-4}$	−0.9%	−7.9%	0.66 / 0.62
$3 \cdot 10^{-6}$	const 10^{-3}	−3.9%	−497.1%	0.64 / 0.20
$3 \cdot 10^{-6}$	decay $10^{-3} \rightarrow 10^{-4}$	−68.8%	−631.2%	0.40 / 0.28

(полный grid — Рисунок 11)

Существенные оговорки прежде чем интерпретировать: (a) **single seed** (42) для всех 24 ячеек; (b) HellaSwag для Qwen3.5-4B-Base — **near-saturation task**: модель стартует с acc=0.71 (random=0.25), и любые улучшения за 500 шагов едва выходят за statistical noise (SE на 100-example acc $\approx \pm 0.045$); (c) loss-движения $2.090 \rightarrow 2.069$ (best case) = **1% relative** — на грани seed variance. Поэтому формулировки ниже — **наблюдения**, а не утверждения.

Наблюдения: (i) В этом регрессионном режиме vanilla MeZO достигает marginally положительного drop +1.0% при $\eta = 10^{-6} + \text{const } \varepsilon = 10^{-3}$ (best cell), D-MeZO-N — +0.3% при $\eta = 3 \cdot 10^{-7}$; gap 1.7 pp вероятно в пределах seed noise. (ii) При $\eta = 3 \cdot 10^{-6}$ **оба** варианта катастрофически расходятся (vanilla loss 3.5–5.2, D-MeZO-N 12.5–15.3) — это lr-too-high эффект, не D-MeZO-N специфичный, но D-MeZO-N деградирует резче из-за Nesterov-momentum amplification (контекст: §6.5, project memory day6_nesterov_b09_diverges). (iii) Warmup-style $\varepsilon(t)$ проигрывает const

во всех 8 ячейках (drop -4.5% до -147%), **третье независимое подтверждение §6.7** в условиях reasoning + 4B + 500 шагов.

Связь с §5.5 (важно): этот sweep **не противоречит** §5.5 D-MeZO-N rescue, поскольку условия разные — другая модель (Qwen3.5 hybrid vs Qwen3 standard), вдвое короче horizon, single seed vs 2 seeds, near-saturation task vs ground-up reasoning. β -decay требует horizon $T \gtrsim T_{\text{decay}}$ чтобы момент успел “разрядиться” до асимптотической SGD-фазы; на 500 шагах $\sim 70\%$ траектории проходит в high- β регионе, что объясняет сложности D-MeZO-N. **Boundary characterization:** D-MeZO-N rescue работает на $T \geq 1000$ rounds (как в §5.5), а на коротких горизонтах его overhead в виде Nesterov-momentum + ρ -clip может проигрывать vanilla.

Future work: validation с 1000+ шагами и multi-seed на той же модели и задаче для определения точной границы applicability. Текущий sweep — **exploratory**, не финальная характеристика.




Рисунок 11. Joint $\text{lr} \times \epsilon \times \text{variant}$ sweep на Qwen3.5-4B-Base / HellaSwag (Colab Blackwell, 500 шаров, single seed=42, 100-example eval). Верхний ряд — vanilla MeZO, нижний — D-MeZO-N ($C=50, \beta=0.9 \rightarrow 0$). Колонки — $\eta \in \{10^{-7}, 3 \cdot 10^{-7}, 10^{-6}, 3 \cdot 10^{-6}\}$. Три $\epsilon(t)$ schedule в каждом panel (const синий, decay-below зелёный, warmup красный). Треугольники-маркеры показывают где траектория выходит за пределы visible y-range (catastrophic divergence при $\eta=3 \cdot 10^{-6}$). Caveat: на этой near-saturation задаче (стартовая acc=0.71, random=0.25) seed-variance $\pm 2\text{pp}$ drop сравнимо с большинством inter-cell разностей; рисунок интерпретируется как exploratory landscape, а не как definitive ranking. Warmup $\epsilon(t)$ проигрывает const во всех 8 ячейках — robust подтверждение §6.7.

6.9 Statistical caveats и применимость findings

Применяем единый rigor-criterion ко всем эмпирическим утверждениям paper. Подавляющее большинство runs — **single seed = 42** или **2 seeds** (Day 5 grid §5.2). Eval-accuracy на 100-200 примерах имеет $\text{SE} \approx \pm 0.04\text{--}0.05$, что сравнимо с inter-cell разностями ≤ 5 pp. Loss-drop $\pm 2\%$ от старта аналогично внутри seed variance band. Поэтому findings paper разделяются на **три категории robust-уровня**:

Robust (cross-replicated effect-size $\gg$ noise): - §6.7 ϵ -autotuner failure — 4 независимых confirmation (2 архитектуры $\times$ 2 stages); large effect (60% drop vs 13–17%). - §6.7 warmup $\epsilon(t)$ loses — 16+ cells cross-arch + cross-variant + cross-task (SST-2, HellaSwag); systematic direction. - §6.4 batch-variance CLT failure — multi-batch ratio растёт от $1.55\times$ до $3.43\times$ с $B \rightarrow 32$, clean monotonic effect. - §5.2 Day 5 federated 2×2 grid — 2 seeds, partition tax $< 13\%$; effect-size robust. - §6.5 $K=3$ multi-direction trade-off — loss/acc Pareto trade-off наблюдается обоими параметрами. - C5/C6 теоремы — математические, rigor устанавливается доказательством, не data.

Tentative (single-seed positive findings, requires multi-seed validation): - §5.5 D-MeZO-N rescue на HellaSwag/Qwen3-4B — single seed, +3.75 pp acc improvement; effect-size on the order of seed variance (~4 pp SE на 100-example eval). Boundary: 1000+ steps, standard transformer. - §5.6 D-MeZO-N v1 single-seed safe-tracking на MathLogicQA/Qwen3.5-4B-Base — устаревший single-seed результат (+1.25 pp acc), **superseded** 3-seed paired валидацией §5.6.2 (Robust, см. §8 A7): combo v2 robustly beats vanilla по loss (−5.5%, 3/3), accuracy +2.3pp статистически незначима. Этот single-seed пункт более не актуален. - §6.8 joint sweep “vanilla wins” / boundary characterization — single seed × 24 cells, best-cell drop +1.0% vs near-rivals в пределах ~2 pp.

Exploratory (preliminary observations): - **Richardson 4-point / 6-point** (§6.7 supplement) — sweet-spot и ranking observation, не fully validated cross-task. (Архивные JSON хранят только losses; verifiable по архиву эффект — это loss: richardson_eq 0.854 vs 2-pt 0.929 на Qwen3-0.6B, т.е. −8.1%. Любые accuracy-числа Richardson взяты из run-логов и по архивному JSON не проверяемы.)

Что это значит для интерпретации: текущие “rescue” и “vanilla wins” findings — **consistent with hypothesis**, но не statistically established. §5.5 ↔ §6.8 contrast (D-MeZO-N сходится / не сходится) объясним *исключительно* boundary conditions (horizon, model arch, task saturation) и **не требует** утверждения “noisy single-seed противоречит другому noisy single-seed”. Для финальной публикации в журнал необходима multi-seed validation (≥3 seeds) на ключевых ячейках; в текущей версии paper эти findings — **directional evidence**, согласованное с теоретическими предсказаниями (Theorem 3 corollary), но не самостоятельно решающее. Robust findings (§6.4, §6.7 warmup, §6.7 autotuner failure, §5.2 grid) основаны на cross-replicated evidence и не зависят от single-seed limitation.

D-MeZO-N: Master Results Table — All Numerical Evidence at a Glance				
Each row: section + setup + metric + statistical-rigor tier + evidence quality. Robust findings cross-replicated; Tentative single-seed; Negative = clean falsification of a stated hypothesis.				
SECTION	SETUP	METRIC	TIER	EVIDENCE
§5.2	Day 5 federated 2×2 grid (topology × distribution) Qwen3.5-4B-Base / SST-2	ring+IID: 0.1271 ± 0.0014 ring+Dir: 0.1402 ± 0.0029 complete+IID: 0.1348 ± 0.0051 complete+Dir: 0.1507 ± 0.0089	[Robust]	2 seeds × 4 cells = 8 runs (partition variance entangled)
§5.4	Day 8 R1d D-MeZO-N v1 vs ablation control (no momentum) ring+Dir worst cell, seed=42	R1d: 0.1291 control: 0.1373 improvement: 6.0%	[Tentative]	1 seed paired comparison (bit-exact for ablation)
§5.5	HellaSwag rescue Qwen3-4B (standard transformer) 1000 rounds	vanilla: 2.5691 → 2.7112 (+5.5% loss, divergence) D-MeZO-N: 2.5691 → 2.4959 (−2.85% loss) Δacc: +6.25pp absolute	[Tentative]	1 seed; SE_acc on 200-eval ≈ ±3.4pp multi-seed pending (Section 19)
§5.6	MathLogicQA Pareto Qwen3.5-4B-Base hybrid Russian symbolic reasoning	vanilla: −49.7% loss / +0pp acc D-MeZO-N: −46.8% loss / +1.25pp acc (Pareto trade-off, not dominance)	[Tentative]	1 seed Explicit Pareto framing in §5.6
§6.4	Batch-variance CLT failure Qwen3-0.6B / SST-2, fixed z B ∈ {1, 2, 4, 8, 16, 32}	Observed σ / CLT-expected ratio 1.55× (B=2) → 3.43× (B=32) monotonic deviation from 1/√B	[Robust]	6-point monotonic trend Direct cross-B comparison
§6.7	ε-autotuner failure Qwen3-0.6B + Qwen3.5-0.8B autotuner picks ε* ∈ {1e-1, 3e-1}	Princeton ε=1e-3 downstream drop: −60.8% / −63.1% autotuner ε* drop: −13.9% / +5.3% (loss UP) 3-6× worse	[Robust]	Cross-arch × cross-stage 4 independent confirmations
§6.7	Warmup ε(t) systematically loses 5 schedules × cross-arch + cross-variant	Warmup ε(t) loses const ε=1e-3 in 16+ cells out of 16 examined (SST-2 + HellaSwag + 4B)	[Robust]	Cross-arch + cross-variant + cross-task mechanism: Taylor validity boundary
§6.7+	Richardson 4-pt + 6-pt falsification of higher-order rescue Qwen3-0.6B + Qwen3.5-0.8B	Unit tests on quintic: PASS (analytic ε² and ε⁴ cancel) LLM downstream: dominated by 2-pt at Princeton ε	[Negative]	128 tests including analytic finite-diff verification
§6.8	Joint lr × ε × variant sweep Qwen3.5-4B-Base / HellaSwag 24 cells (4 lr × 3 sched × 2 var) × 500 steps	Best vanilla: η=1e-6 + const ε=1e-3 → +1.0% drop Best D-MeZO-N: η=3e-7 + const → +0.3% drop broad lr=3e-6 catastrophic	[Tentative]	1 seed × 24 cells Near-saturation task; gap inside SE

All Tentative rows benefit from multi-seed validation. See docs/robustness_matrix.md for full statistical classification.

Рисунок 12. Master results table — сводное представление всех численных результатов §5–§6 с классификацией statistical-rigor tier. Robust (зелёный) — cross-replicated; Tentative (жёлтый) — single-seed, requires multi-seed validation; Negative (красный) — clean falsification of a stated hypothesis. Каждая строка содержит section, setup, metric, tier-badge и evidence quality. Все Tentative rows выигрывают от multi-seed validation; полная классификация — docs/robustness_matrix.md.

Future work на rigor-направлении: (а) re-run §5.5 + §6.8 best-cells с 3 seeds для получения 95% CI на drop% и асс; (б) расширить eval pool до 500 examples ($SE \approx \pm 0.02$); (в) paired comparisons (одинаковый seed для variant pair) для контроля seed-variance в paired t-test.

6.10 Синтез negative findings: когда наивные интуиции про variance reduction в fp16 MeZO проваливаются

Пять отдельных negative results §6.4–§6.8 имеют общий механизм, который **полезно сформулировать явно** как контр-эвристический инсайт для будущих работ по ZO-fine-tuning LLM:

Finding	“Наивная интуиция”	Реальность fp16 MeZO	Section
Batch-variance CLT failure	Variance уменьшается как $1/B \rightarrow$ используй большие batches	Variance saturates при $B \geq 8$; dominantный источник шума — выбор z , не sampling данных	§6.4
ϵ -autotuner failure	Bias-variance proxy autotuner находит “оптимальный” ϵ	Проxy измеряет $\text{tr}(H)$, не bias gradient-оценщика; autotuner выбирает $\epsilon^* \gg 10^{-3}$ который проигрывает downstream в 3-6×	§6.7
Warmup $\epsilon(t)$ systematic failure	Start large ϵ для variance reduction $\rightarrow$ decay to small для precision	Все 16+ cells cross-arch + cross-variant теряют const 10^{-3} — biased early-steps создают невозвратный drift trajectory	§6.7 follow-up
Richardson 4-pt не помогает	Cancel $O(\epsilon^2)$ bias $\rightarrow$ можно использовать большой ϵ	Работает на квинтической loss (unit test pass), но fail на LLM при $\epsilon \geq 10^{-2}$ — 2ϵ -probe оставляет Taylor regime	§6.7 supplement
6-pt Romberg $\leq$ 4-pt $\leq$ 2-pt	Higher-order finite-diff $\rightarrow$ меньше bias	6-pt variance amplification $\sim 2.2\times$ доминирует bias reduction; Princeton 2-pt оптимален	§6.7 supplement

Объединяющий механизм: в fp16 MeZO loss-landscape **выходит из Taylor-validity range** при $\epsilon \gtrsim 10^{-2}$ (на Qwen-arch), причём граница зависит от архитектуры (hybrid linear-attn робастнее full-attn). Catastrophic cancellation в $(L^+ - L^-)/2\epsilon$ — нижняя граница для ϵ (roughly 10^{-3} в fp16), а Taylor-3 nonlinearity — верхняя ($\epsilon \lesssim 10^{-2}$). Princeton default $\epsilon = 10^{-3}$ оказывается **near-optimal balance**, а not arbitrary choice — нашлось apriori, до полного понимания границ.

Practical recipe для практиков fp16 ZO-fine-tuning (наша recommendation):

1. ϵ : const 10^{-3} (Princeton) — не tune, не schedule. Refinement ниже (10^{-4}) marginal +4pp выигрыш только на hybrid arch.
2. B : 4–8 — больше не даёт variance reduction.
3. **Variance reduction:** K -direction averaging (свежие z_k) поверх batch-scaling — §6.5.
4. **Estimator:** 2-point central diff (Princeton) — higher-order не помогает.
5. **lr:** 10^{-6} для 4B (или $3 \cdot 10^{-7}$ если хочется conservative); горизонт ≥ 1000 шагов для D-MeZO-N rescue.

Эти рекомендации based on cross-replicated cross-arch evidence (§6.7 robust per docs/robustness_matrix.md); они должны переноситься на широкий range LLM ZO-fine-tuning без re-tuning.

6.11 D-MeZO-N v2 recipe: adaptive ρ-clip + drift-reset

6.11.1 Mechanism design

B1 — Adaptive ρ-clip:

$$C_t = \alpha \cdot \text{quantile}_{0.95}(\{|\hat{\rho}|\}_{\text{last 50 rounds}}), \quad \alpha = 1.3$$

Threshold подстраивается под наблюдаемое распределение $\hat{\rho}$. 95-й перцентиль robust к outliers, $\alpha = 1.3$ — empirical sweet spot. На Qwen3.5-4B-Base / MathLogicQA наблюдаемый range $C_t \in [132, 321]$ (data-driven) — **в 3–6× больше** фиксированного $C = 50$ из v1, что preserves signal while bounding outliers.

B5 — Drift-reset:

```
если eval_loss[t] - min(eval_loss[t-50:t]) > 0.1:
    v_t ← 0
    counter += 1
```

Surgical zero на velocity buffer при детекции uptick — Lyapunov potential-component ($L - L^*$) продолжает сокращаться, kinetic component $\|v\|^2$ сбрасывается без trainable parameter mutation.

6.11.2 Multi-seed validation на paper-scale

Local ablation на Qwen3.5-0.8B / MathLogicQA / 2 seeds выявил **accuracy paradox B1 alone** (loss-parity vs vanilla, но −17pp acc) и установил combo как кандидат. (При $n = 2$ seeds paired bootstrap имеет лишь 3 различных resample, поэтому соответствующий интервал на Δ_{acc} — консервативный диапазон, а не калиброванный CI.) **Paper-scale 3-seed paired validation** на Qwen3.5-4B-Base / MathLogicQA подтвердил:

Variant	Mean loss ± std	Mean acc	Δ loss vs vanilla	Direction (3 seeds)
vanilla	1.368 ± 0.018	0.377	reference	—
v1 fixed $C = 50$	1.463 ± 0.007	0.377	+7.0% worse	3/3 worse
B5 alone	1.456 ± 0.003	0.377	+6.4% worse	3/3 worse
B1 alone (adaptive)	1.299 ± 0.021	0.390	−5.1%	3/3 wins loss
B1+B5 = combo (D-MeZO-N v2)	1.293 ± 0.010 ★	0.400	−5.5%	3/3 wins loss

Direction consistency для combo (3 seeds): - $\Delta \text{loss} = (-7.0\%, -3.6\%, -6.0\%)$ — **3/3 negative** (combo wins) - $\Delta \text{acc} = (-1\text{pp}, +8\text{pp}, 0\text{pp})$ — **mean +2.3pp**, никогда существенно negative

Наименьший std loss среди вариантов, улучшающих vanilla (0.010 vs B1 alone 0.021; сам vanilla 0.018) — combo достигает **stability** через mechanism complementarity. (Drift-only имеет ещё меньший std loss 0.0035, но он равномерно «застрял» на худшем loss +6.4% — это не стабильность хорошего решения, а артефакт.)

6.11.3 Аналогия с автомобилем

- **v1 (fixed C=50):** ограничитель скорости установлен на 50 — в городе ок, на трассе бесполезен.
- **B1 alone:** круиз-контроль адаптируется к скорости трафика — оптимально на средней трассе, но без ABS заносит на скользкой (drift up на s=43 после R600).
- **B5 alone:** ABS без круиз-контроля — не помогает если изначальная скорость неверна.
- **Combo (B1+B5) = D-MeZO-N v2:** круиз-контроль (adaptive clip) + ABS (drift-reset) — работает на любой трассе.

Recommended deployment recipe: - $\eta = 3 \cdot 10^{-7}$ (default Princeton MeZO) - $\varepsilon = 10^{-3}$ (Princeton default; §6.7 confirmed cross-arch) - Adaptive ρ -clip: window=50, quantile=0.95, $\alpha = 1.3$ - Drift-reset: window=50, threshold=0.1 - β -schedule: linear $0.9 \rightarrow 0$ - No weight_decay (Princeton convention)

6.12 Privacy-preserving D-MeZO-N (DP- σ -sweep)

Расширяем D-MeZO-N v1 Gaussian-шумом на clipped $\hat{\rho}$ — каждый MeZO-step превращается в применение Gaussian-механизма Дворка-Рота. ρ -клип C **служит естественной L2-чувствительностью**, поэтому DP не требует дополнительного per-sample gradient clipping (контраст с DP-SGD).

Per-round guarantee: $\varepsilon_1 = \frac{C\sqrt{2\ln(1.25/\delta)}}{\sigma}$. Для $C = 50, \delta = 10^{-3}$: $\varepsilon_1 = 188.8/\sigma$.

Эксперимент (Colab Blackwell, 119 min, Qwen3.5-0.8B / MathLogicQA / 200 раундов / 8 variants $\times$ 2 seeds):

Доступность данных. Сырые JSON σ -sweep лежат в архиве Colab-запуска (dmezo_runs/ на Drive, run от 2026-05-20); sweep воспроизводим через scripts/sweep_dp_sigma.py . В репозитории experiments/diagnostics/ покрывает одну DP-конфигурацию ($\sigma = 0.5$).

Variant	σ	ε	Loss (mean $\pm$ std)	Acc	Δ_{loss} vs no-DP D-MeZO-N
Vanilla (no DP, no momentum)	—	∞	1.4698 $\pm$ 0.001	0.310	—
D-MeZO-N v1 (no DP)	—	∞	1.7854 $\pm$ 0.018	0.265	0% (ref)
+ DP, σ =0.5	0.5	378	1.9075 $\pm$ 0.054	0.255	+6.8%
+ DP, σ =2.0	2.0	94	1.8933 $\pm$ 0.065	0.255	+6.0%
+ DP, σ =5.0	5.0	38	1.8828 $\pm$ 0.098	0.250	+5.5%
+ DP, σ =10.0	10.0	19	1.9068 $\pm$ 0.076	0.230	+6.8%
+ DP, σ =19.0	19.0	★ 10	1.8967 $\pm$ 0.093	0.265	+6.2%
+ DP, σ =50.0	50.0	4	1.9116 $\pm$ 0.036	0.275	+7.1%

Главное наблюдение: frontier статистически плоский во всём диапазоне $\sigma \in [0.5, 50]$. Все CI пересекаются (при $n = 2$ seeds paired bootstrap имеет лишь 3 различных resample; при $n = 3$ — 10, поэтому приводимые интервалы — консервативные диапазоны, а не калиброванные CI). Acc при ε =10 (0.265) **идентичен** no-DP baseline (0.265).

Headline claim: “Первый decentralized federated ZO оптимизатор с формальной ($\epsilon = 10, \delta = 10^{-3}$)-DP гарантией за раунд на LLM с $\sim 6\%$ utility cost.” **Важное ограничение:** это **per-round** гарантия; **T-round composition** через базовую теорему даёт $\epsilon_T = T \cdot \epsilon_1 \approx 2000$ при $T = 200$ (бесполезно для **end-to-end DP**). **RDP/Moments accountant** даёт $O(\sqrt{T})$ — всё ещё большое при **long training**. **Subsampling amplification** (Abadi 2016) — **recommended future direction** для практического **end-to-end DP**.

Почему теоретический шум-пол T4 не наблюдается? Theorem 4 (см. docs/theory_rigorous.md §6.5, Lemma 8) предсказывает шум-пол $\frac{2(C^2 r(H) + \sigma^2 d) \ell}{3\mu}$ — clip-noise выровнен с градиентом и масштабируется с effective rank $r(H)$, а DP-noise ξz изотропен и масштабируется с **полной** размерностью d (в коде scalar noise добавляется к $\hat{\rho}$ после клипа, src/dmezo/mezo/step.py:193). При $\sigma = 0$ эта оценка точно сводится к T3. Член $\sigma^2 d$ должен **доминировать** над $C^2 r(H)$ для $\sigma > C \sqrt{r(H)/d} \approx 0.02$. Однако: - При $T = 200$ раундов мы в **transient regime** — шум-пол не достигнут. - Effective d возможно $\ll$ total params (vision frozen, alignment z с ∇L). - При финитном η и малом T SDE-аналитика — не tight predictor.

Это **feature, не bug**: реальные deployments с $T \leq 1000$ раундов также enjoy этот gap.

Composition caveat (честно). Per-round ϵ для **одного раунда**. T-round composition: - Basic (Dwork-Roth T3.16): $\epsilon_T = T\epsilon_1 = 2000$ при $T = 200, \epsilon_1 = 10$ (бесполезно). - Advanced (Dwork-Rothblum-Vadhan 2010): формально даёт $\sqrt{T}$ -scaling, но второй член $T\epsilon_1(e^{\epsilon_1} - 1)$ взрывается при $\epsilon_1 = 10$ (фактически $\sim 10^7$). Advanced/RDP composition даёт реальную экономию **только в режиме** $\epsilon_1 \ll 1$ (где $e^{\epsilon_1} - 1 \approx \epsilon_1$); при $\epsilon_1 = 10$ доминирует **basic** composition. - **RDP / Moments accountant** (Mironov 2017, Abadi 2016): tighter via Rényi. Per-round RDP-коэффициент Gaussian-механизма **включает L2-чувствительность**: $\epsilon_\alpha = \alpha C^2 / (2\sigma^2)$ (а не $\alpha / (2\sigma^2)$); после T раундов $(\alpha, T\alpha C^2 / (2\sigma^2))$ -RDP, что всё ещё $O(\sqrt{T})$ для Gaussian. - **Subsampling amplification** (Abadi 2016): уменьшает per-step ϵ на batch fraction q — straightforward extension для future work.

Что нужно для useful training-level budget: достижение полезного бюджета на всё обучение требует per-round $\epsilon_1 < 1$ (т.е. бóльшего σ) — именно этот режим должна целить полная трактовка через RDP-accountant (future work).

Позиция paper: заявляем per-round ϵ (стандарт для one-shot federated fine-tuning); T-round composition признаём limitation; subsampling amplification — recommended future direction.

7. Ограничения и future work

Эмпирические ограничения. (а) Day 5 SST-2 grid покрыт лишь $n = 2$ seeds; HellaSwag (§5.5) остаётся single-seed (multi-seed rescue validation подготовлена, pending Colab budget). MathLogicQA (§5.6) **финализирован**: полный 5 variants $\times$ 3 seeds sweep (15 cells, §5.6.2) завершён, headline-улучшение по loss ($\Delta = -5.5\%$, 3/3 same direction, paired $t = 5.3$, $p < 0.05$) multi-seed валидировано. (б) Scale-up за пределы 4-клиентского / 4B-параметрового режима — реальные FL-деплой имеют 100+ клиентов и 8B+ модели; на этом масштабе мы не тестировали. (в) Генеративные задачи (SAMSum, GSM8K) не исследованы — §5.5/§5.6 покрывают multi-choice reasoning, не free-form generation. (г) Head-to-head сравнение с **FedKSeed** проведено (3 seeds $\times$ 500 раундов на Qwen3.5-4B-Base / MathLogicQA, артефакты в head-to-head/): D-MeZO-N v2 beats FedKSeed по loss 3/3 seeds (1.334 ± 0.014 vs 1.466 ± 0.022); асс-тренд положительный ($\Delta_{\text{асс}} = +5.3\text{pp}$), но bootstrap CI $[-2.0, +14.0]$ pp включает 0 — не значим при $n=3$ и не заявляется. Ferret / FedZeN head-to-head пока не проведены — эти интеграции остаются нетривиальной работой по коду.

Теоретические ограничения. Theorem 3 (non-convex PL + heavy-ball momentum + ZO + ρ -clipping + β -decay) доказана в docs/theory_rigorous.md §3 и эмпирически валидирована в двух режимах: как **rescue** на HellaSwag (§5.5)

и как **safe convergence** на MathLogicQA (§5.6). Открытыми остаются: (а) полное decentralized-расширение (mixing matrix W с $\rho_W < 1$ в комбинации с momentum + clipping); (б) transient acceleration vs asymptotic — наша теория даёт rate $1 - 3\eta\mu/2$, того же порядка, что и rate plain SGD под PL ($1 - 2\eta\mu$), но эмпирически Nesterov-MeZO даёт early-stage speedup, не объяснённый текущей теорией; (в) константа PL μ для LLM глобально не доказана — локально на траектории переобученной модели это правдоподобно (Liu–Zhu–Belkin 2022), однако мы используем её как предположение.

Алгоритмические ограничения. Рекомендованный D-MeZO-N требует ручного выбора ρ -clip порога C и формы β -расписания. Adaptive вариант, настраивающий C по наблюдаемому распределению $\hat{\rho}$ и адаптирующий β по slope валидационного loss, упростил бы deployment. Multi-direction MeZO (K -direction SPSA averaging) — естественное variance-reduction расширение, которое должно сделать look-ahead Нестеров tractable.

8. Калиброванное резюме достижений (на 2026-05-21, FINAL)

Четыре группы, ранжированных по силе свидетельства.

Группа А — Robust (multi-seed validated, paper-ready)

Claim	Свидетельство	Раздел
A1. Federated MeZO на hybrid linear-attention LLM (Qwen3.5-4B-Base)	Day 1 + 2×2 cross-arch grid	§5.1, §5.2
A2. Топологии complete/ring/non-IID Dir(0.5) сходятся, partition-tax <13%	Day 5 2×2 grid (2 seeds × 4 cells)	§5.2
A3. Четыре теоремы (T1, T2, T3, T4) с полными доказательствами; T3 — первая гарантия устойчивости ZO heavy-ball (PL-режим)	docs/theory_rigorous.md	§4, §6.7, §6.12
A4. Per-round ($\epsilon=10$, $\delta=10^{-3}$)-DP с ~6% utility cost; dual-use ρ -clip как L2-sensitivity	16 cells σ -sweep × 2 seeds, frontier flat	§6.12
A5. Communication: 16 байт/раунд (1 float + 1 int) при update_share consensus	Алгоритмический + tests	§3.4
A6. Independent z_i per client $\rightarrow 1/n$ variance reduction no data и direction noise (differentiator vs FedKSeed shared-z)	Theorem 2 + code verification	§3.3, §4.4
A7. ★ D-MeZO-N v2 = combo (B1+B5) beats vanilla MeZO на Qwen3.5-4B-Base / MathLogicQA / 3 seeds paired: Δ loss = -5.5% (3/3 same direction, paired t = 5.3, p < 0.05). Наименьший std loss среди вариантов, улучшающих vanilla (0.010; vanilla 0.018). Accuracy: +2.3pp mean, статистически незначима (p $\approx$ 0.5; для прозрачности)	15-cell multi-seed run	§5.6
A8. D-MeZO-N v2 beats FedKSeed (Qin 2024) по loss 3/3 seeds в paired head-to-head (FedKSeed при default $K = 4096$, 500 раундов; асс-сравнения не значимы при n=3)	3 метода × 3 seeds	§7 (г), D2; артефакты в head-to-head/

Группа В — Promising (single-seed positive, multi-seed pending)

Claim	Свидетельство	Caveat
B1. D-MeZO-N v2 rescue на HellaSwag (vanilla diverges, v2 converges +3.75pp)	n=1 seed на Qwen3-4B	Multi-seed validation script готов, pending Colab budget
B2. D-MeZO-N v2 transient 3× speedup на SST-2 (Day 8 R1b R100→R300)	n=1 seed	Не доказан формально (открытый вопрос: transient acceleration в ZO heavy-ball; asymptotic acceleration запрещено Bottou-Curtis-Nocedal 2018)

Группа C — Empirically falsified (multi-seed honest negatives)

Изначальный claim	Falsification	Раздел
C1. “D-MeZO-N v1 (fixed C=50) +1.25pp асс на MathLogicQA”	3-seed paired: 3/3 worse than vanilla (+7.0% loss)	§5.6.2
C2. “Drift-reset B5 alone достаточен”	3-seed paired: 3/3 worse than vanilla (+6.4% loss) — нужен B1 (adaptive clip) для preservation signal	§5.6.2
C3. “True-Nesterov look-ahead ускоряет”	Diverges 7× быстрее heavy-ball (R20 vs R140)	Day 6b
C4. “K=3 multi-direction strictly improves”	Equal-compute: loss +41.6% хуже, асс Pareto trade-off	§6.5
C5. “Adaptive $\varepsilon(t) > \text{Princeton } \varepsilon=10^{-3}$ ”	Loses by 3-6× downstream cross-arch	§6.7
C6. “ $O(1/T^2)$ Nesterov rate асимптотически”	Bottou-Curtis-Nocedal 2018 T5.1 запрещает для stochastic non-convex с $\sigma > 0$	§6.10

Группа D — Pending validation (future work)

Задача	Status	Compute estimate
D1. HellaSwag rescue multi-seed (3 seeds × Qwen3-4B / D-MeZO-N v2)	Script готов	~5h Blackwell
D2. Head-to-head vs FedKSeed DONE (3 seeds × 500 раундов, Qwen3.5-4B-Base / MathLogicQA): D-MeZO-N v2 beats FedKSeed по loss 3/3 seeds (1.334 vs 1.466); асс-тренд +5.3pp не значим (CI включает 0); артефакты в head-to-head/	✅ выполнено (A8)	—
D3. D-MeZO-N v2 + DP composition (v2 + $\varepsilon=10$)	Configured	~2h
D4. Scale-up: Qwen3-8B / SST-2 или n=8 clients	Только конфиги	~6h
D5. Generative task pilot (SAMSum или GSM8K)	Infrastructure needed	~1 day + 5h compute
D6. Full decentralized Theorem 3 (открытый вопрос: decentralized extension of T3)	Theory	60–80h

Е. Самый сильный publishable claim (на 2026-05-21, FINAL)

D-MeZO-N v2 = combo (adaptive ρ -clip B1 + drift-reset B5) — peer-to-peer decentralized federated zeroth-order оптимизатор для дообучения LLM, с (i) **empirically demonstrated multi-seed validated улучшением over vanilla MeZO** на paper-scale (Qwen3.5-4B-Base / MathLogicQA / 3 seeds paired): $\Delta \text{loss} = -5.5\%$ (3/3 same direction, paired t = 5.3, $p < 0.05$), наименьший std loss среди вариантов, улучшающих vanilla (0.010 vs vanilla 0.018; drift-only имеет меньший std 0.0035, но застрял на худшем loss); точность +2.3pp в среднем — статистически незначима ($p \approx 0.5$), приводится для прозрачности; (ii) **closed-form Lyapunov-сходимостью**

под **PL + heavy-ball + β -decay + ρ -clip** (Theorem 3 — первая гарантия устойчивости ZO heavy-ball в PL-режиме; same asymptotic rate как plain SGD, как и должно быть согласно Bottou-Curtis-Nocedal 2018); (iii) **формальной per-round ($\varepsilon=10$, $\delta=10^{-3}$)-DP гарантией** через dual-use ρ -clip как L2-sensitivity (Theorem 4) с $\sim 6\%$ utility cost (T-round composition — ограничение, признаётся явно в §6.12); (iv) **independent z_i per client** $\rightarrow 1/n$ **variance speedup по обеим компонентам шума** (data + direction) при 16 байт/раунд коммуникации (update_share consensus mode).

Что **не** заявляется (группа C): асимптотическое ускорение над vanilla MeZO (transient в группе B остаётся open problem), $O(1/T^2)$ rates, K-direction strict improvement, $\varepsilon(t)$ schedule wins, accuracy gains за пределами seed noise на rescue regime (HellaSwag pending). Что **в работе** (группа D): HellaSwag rescue multi-seed, scale-up (head-to-head FedKSeed уже **выполнен** — D-MeZO-N v2 beats FedKSeed по loss 3/3 seeds, асс-тренд не значим; см. A8/D2).

9. Заключение

Мы представили D-MeZO-N — Decentralized Federated MeZO с Nesterov-стабилизацией — и установили его как жизнеспособный peer-to-peer федеративный оптимизатор для дообучения LLM. Восемь контрибуций (C1–C8) покрывают (i) поддержку новой архитектуры (Qwen3.5 гибридная linear-attention), (ii) устойчивость к экстремальной неоднородности данных, (iii) пренебрежимо малую стоимость топологии при $n = 4$, (iv) рецепт **D-MeZO-N v2 (combo B1+B5)** с paper-scale multi-seed validated улучшением по loss ($\Delta = -5.5\%$, 3/3 seeds, paired $t = 5.3$, $p < 0.05$) и победой над FedKSeed-at-default по loss 3/3 seeds, (v) independent z_i per client с $1/n$ variance reduction по обеим компонентам шума при 16 байт/раунд коммуникации, (vi) Theorem 3 (PL+momentum+clip) — насколько нам известно, первую гарантию устойчивости ZO heavy-ball в PL-режиме (open question: decentralized extension of T3), (vii) Theorem 4 + первую формальную per-round DP-гарантию для decentralized federated ZO на LLM, (viii) честные multi-seed validated негативы (v1 falsified 3/3, drift-only 3/3, look-ahead diverges, K=3 trade-off, $\varepsilon(t)$ -schedules проигрывают). Полный репозиторий публично доступен. Открытые направления — масштабирование до 100+ клиентов, multi-seed валидация для downgrade tentative $\rightarrow$ robust, generative-задачи, T-round DP composition через RDP+subsampling.

Доступность кода и данных. Весь код, конфиги, тесты и закоммиченные сырые JSON результатов доступны в репозитории github.com/Siesher/dmezo. Пути вида docs/..., scripts/..., tests/..., notebooks/..., упоминаемые в статье, указывают на файлы в этом репозитории; в частности, полные доказательства — в docs/theory_rigorous.md, headline-данные — в experiments/diagnostics/validate_multiseed_fed_Qwen_Qwen3p5-4B-Base_mathlogicqa.json и head-to-head/head_to_head_fedkseed_Qwen_Qwen3p5-4B-Base_mathlogicqa.json.

Список литературы

- Abadi, M., Chu, A., Goodfellow, I., McMahan, H. B., Mironov, I., Talwar, K., Zhang, L. (2016). Deep learning with differential privacy. ACM CCS 2016. arXiv:1607.00133.
- Aybat, N. S., Fallah, A., Gurbuzbalaban, M., Ozdaglar, A. (2019). A universally optimal multistage accelerated stochastic gradient method. NeurIPS 2019.
- Beznosikov, A., Richtárik, P., Diskin, M., Ryabinin, M., Gasnikov, A. (2022). Distributed methods with compressed communication for solving variational inequalities, with theoretical guarantees. NeurIPS 2022. arXiv:2207.10792.
- Bottou, L., Curtis, F. E., Nocedal, J. (2018). Optimization methods for large-scale machine learning. SIAM Review 60(2):223–311. arXiv:1606.04838.

- Dwork, C., Roth, A. (2014). The algorithmic foundations of differential privacy. *Foundations and Trends in Theoretical Computer Science* 9(3–4):211–407.
- Dwork, C., Rothblum, G. N., Vadhan, S. (2010). Boosting and differential privacy. *FOCS 2010*.
- Gasnikov, A., Dvinskikh, D., Dvurechensky, P., Gorbunov, E., Beznosikov, A., Lobanov, A. (2023). Randomized gradient-free methods in convex optimization. *Encyclopedia of Optimization* (Springer), pp. 1–15. arXiv:2211.13566.
- Hsu, T.-M. H., Qi, H., Brown, M. (2019). Measuring the effects of non-identical data distribution for federated visual classification. arXiv:1909.06335.
- Karimi, H., Nutini, J., Schmidt, M. (2016). Linear convergence of gradient and proximal-gradient methods under the Polyak-Łojasiewicz condition. *ECML-PKDD 2016*.
- Koloskova, A., Loizou, N., Boreiri, S., Jaggi, M., Stich, S. U. (2020). A unified theory of decentralized SGD with changing topology and local updates. *ICML 2020*. arXiv:2003.10422.
- Li, Z., Ying, B., Liu, Z., Dong, C., Yang, H. (2024). Achieving dimension-free communication in federated learning via zeroth-order optimization. *ICLR 2025*. arXiv:2405.15861.
- Liu, C., Zhu, L., Belkin, M. (2022). Loss landscapes and optimization in over-parameterized non-linear systems and neural networks. *Applied and Computational Harmonic Analysis* 59:85–116.
- Malladi, S., Gao, T., Nichani, E., Damian, A., Lee, J. D., Chen, D., Arora, S. (2023). Fine-tuning language models with just forward passes. *NeurIPS 2023*. arXiv:2305.17333.
- Maritan, A., Ridolfi, A., Notarstefano, G. (2024). FedZeN: a zeroth-order Newton-style method for federated learning. arXiv:2309.17241.
- McMahan, B., Moore, E., Ramage, D., Hampson, S., y Arcas, B. A. (2017). Communication-efficient learning of deep networks from decentralized data. *AISTATS 2017*.
- Mironov, I. (2017). Rényi differential privacy. *IEEE Computer Security Foundations Symposium (CSF) 2017*. arXiv:1702.07476.
- Nesterov, Y., Spokoiny, V. (2017). Random gradient-free minimization of convex functions. *Foundations of Computational Mathematics* 17(2):527–566.
- Polyak, B. T. (1964). Some methods of speeding up the convergence of iteration methods. *USSR Computational Mathematics and Mathematical Physics* 4(5):1–17.
- Qin, Z., Chen, D., Qian, B., Ding, B., Li, Y., Deng, S. (2024). FedKSeed: federated full-parameter tuning of billion-sized language models with communication cost under 18 kilobytes. *ICML 2024*. arXiv:2312.06353.
- Sadegh, P., Spall, J. C. (1998). Optimal random perturbations for stochastic approximation using a simultaneous perturbation gradient approximation. *IEEE Transactions on Automatic Control* 43(10):1480–1484.
- Sadiev, A., Borodich, E., Beznosikov, A., Dvinskikh, D., Chezhegov, S., Tappenden, R., Takáč, M., Gasnikov, A. (2022). Decentralized personalized federated learning: Lower bounds and optimal algorithm for all personalization modes. *EURO Journal on Computational Optimization* 10:100041.

- Shu, Y., Yao, W., Hu, S. X. (2024). Ferret: federated full-parameter tuning at scale for large language models. arXiv:2409.06277.
- Spall, J. C. (1992). Multivariate stochastic approximation using a simultaneous perturbation gradient approximation. IEEE Transactions on Automatic Control 37(3):332–341.
- Spall, J. C. (1997). A one-measurement form of simultaneous perturbation stochastic approximation. Automatica 33(1):109–112.
- Spall, J. C. (2000). Adaptive stochastic approximation by the simultaneous perturbation method. IEEE Transactions on Automatic Control 45(10):1839–1853.
- Stich, S. U. (2019). Local SGD converges fast and communicates little. ICLR 2019.
- Yang, T., Lin, Q., Li, Z. (2016). Unified convergence analysis of stochastic momentum methods for convex and non-convex optimization. arXiv:1604.03257.
- Zellers, R., Holtzman, A., Bisk, Y., Farhadi, A., Choi, Y. (2019). HellaSwag: Can a machine really finish your sentence? ACL 2019. arXiv:1905.07830.